華中科技大學

本科生毕业设计

水下图像增强算法的设计与实现

院　　系	计算机科学与技术
专业班级	计科 2208
姓　　名	张煜轩
学　　号	U202215436
指导教师	许向阳

2026 年 5 月 14 日

学位论文原创性声明

本人郑重声明：所呈交的论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包括任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名：　　2026 年 5 月 14 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保障、使用学位论文的规定，同意学校保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士论文评选机构将本学位论文的全部或部分内容编入有关数据进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于 1、保　密□，在　　年解密后适用本授权书

2、不保密☑。

（请在以上相应方框内打“√”）

作者签名：　　2026 年 5 月 14 日

导师签名：　　2026 年 5 月 14 日

摘 要

水下光学成像质量直接关系到海洋资源开发的广度与深度。水体介质对光的吸收和散射作用显著，导致原始图像色彩畸变、对比度低下，给目标识别与深海作业可靠性带来挑战。退化图像的视觉增强，因此成为提升水下感知能力的一项核心技术。

本文提出一种混合注意力 U 型增强网络（Hybrid attention U-shaped underwater Enhancement Network, HUENet）及配套集成化演示系统。其核心是由卷积神经网络（CNN）与视觉变换器（Vision Transformer, ViT）构成的混合双分支架构。数据流经编码层级时，残差块（Residual Block, ResBlock）利用残差连接捕获局部边缘细节，强化了纹理表征，同时保证深层训练的数值稳定性。瓶颈层是架构的核心。它通过多头自注意力（Multi-Head Self-Attention, MHSA）机制建立长程依赖，从而精准修正大尺度全局色偏。复合约束函数由像素损失、结构相似度（Structural Similarity, SSIM）损失和色彩恒常性损失组合而成。模型在真实水下图像增强基准数据集（Underwater Image Enhancement Benchmark, UIEB）与增强水下视觉感知数据集（Enhancement of Underwater Visual Perception, EUVP）上交替迭代，提升了应对多变水质的鲁棒性。我们基于 Streamlit 框架实现了一套演示系统，集成数据集管理、单图实时增强与批量性能评测功能，可自动统计多维度评价指标并生成评测报表。

实验结果表明，增强图像的峰值信噪比和结构相似度均达到较高水平，水下色彩质量评价指标也表现优异。结论证实，所提算法有效缓解了散射模糊与光谱衰减畸变，水下视觉质量显著提升，泛化性能较强。

关键词：计算机视觉；水下图像增强；视觉变换器；混合注意力机制；深度学习

Abstract

The quality of underwater optical imaging directly determines how extensively and deeply we can exploit marine resources. Because water strongly absorbs and scatters light, raw underwater images typically suffer from severe color distortion and low contrast, which in turn complicates target recognition and undermines the reliability of deep-sea operations. As a result, enhancing the visual quality of degraded underwater images has become a critical technique for advancing underwater perception capabilities.

This paper introduces a Hybrid Attention U-shaped Underwater Enhancement Network (HUENet), along with an integrated demonstration system. The core of the method is a hybrid dual-branch architecture that combines Convolutional Neural Networks (CNNs) and Vision Transformers (ViTs). As data passes through the encoder layers, residual blocks (ResBlocks) use skip connections to capture fine local edge details. This approach not only improves texture representation but also maintains numerical stability during the training of deep networks. At the center of the architecture lies the bottleneck layer, which leverages Multi-Head Self-Attention (MHSA) to model long-range dependencies, enabling precise correction of large-scale global color casts. The model is trained using a composite loss function that combines pixel loss, Structural Similarity (SSIM) loss, and color constancy loss. We trained the model with alternating iterations on the Underwater Image Enhancement Benchmark (UIEB) and the Enhancement of Underwater Visual Perception (EUVP) datasets, which improved its robustness across varying water conditions. To demonstrate the practical value of our work, we developed a Streamlit-based demonstration system. It supports dataset management, real-time single-image enhancement, and batch performance evaluation, automatically computing a comprehensive set of metrics and generating evaluation reports.

Experimental results show that the enhanced images achieve high scores in Peak Signal-to-Noise Ratio (PSNR) and Structural Similarity (SSIM), and also perform strongly on underwater color quality metrics. Our findings confirm that the proposed algorithm effectively mitigates blur caused by scattering and color distortion due to

spectral attenuation, leading to substantial improvements in underwater visual quality and good generalization performance across different scenarios.

Keywords: Computer Vision, Underwater Image Enhancement, Vision Transformer, Hybrid Attention Mechanism, Deep Learning

目 录

摘 要 ..... **I**
Abstract ..... **III**
1 绪 论 **1**
1.1 课题背景、目的与意义 1
1.2 国内外研究现状 4
1.3 论文的主要内容与结构 9
2 基本理论 **11**
2.1 水下光学成像物理模型 11
2.2 水下图像增强技术方案对比与确立 12
2.3 水下图像质量评价指标 13
2.4 Streamlit 交互式应用框架 16
2.5 本章小结 17
3 HUENet 算法设计 **18**
3.1 功能需求 18
3.2 网络框架 18
3.3 功能模块设计 19
3.4 复合损失函数设计 23
3.5 本章小结 24
4 HUENet 增强算法与演示系统实现 **25**
4.1 数据预处理 25
4.2 算法核心模块实现 26
4.3 演示系统设计与实现 28
4.4 本章小结 33
5 实验结果与分析 **34**
5.1 实验设置与数据集 34
5.2 定性分析（视觉效果对比） 36
5.3 定量指标评估 38
5.4 消融实验 40

5.5 本章小结.....41
6 总结与展望.....42
参考文献.....44
致 谢.....47

1 绪 论

本章从水下图像增强的研究背景与技术地位出发，对课题目的与现实意义进行了说明。接着，对国内外研究现状进行了梳理，并对物理模型、卷积神经网络（CNN）、视觉变换器（Vision Transformer,ViT）和生成对抗网络（Generative Adversarial Network,GAN）在该领域的技术演进作了分析。最后对主要研究内容、技术路线及论文的整体组织结构作出具体说明。

1.1 课题背景、目的与意义

1.1.1 研究背景与趋势

水下视觉感知（Underwater Visual Perception）是海洋资源勘探、水下工程运维、水下考古探测和海洋生态监测等领域不可或缺的技术支柱。光学成像设备直观、信息量大、部署也灵活，因此一直是水下环境感知的首选。然而，水下光学环境与陆地大气截然不同——水体对光线进行强烈的选择性吸收，加上多重散射，水下图像的质量普遍大打折扣。红光、黄光这些长波段在水里衰减得最快，蓝光和绿光反而保留得更多，因此画面常常是蓝绿色。与此同时，悬浮泥沙、浮游生物以及各种杂质颗粒会散射传播中的光线，形成一种类似“雾化”的效果[1]，让画面对比度下滑，细节和边缘变模糊，目标轮廓也不容易分辨。这些退化直接拖累了目标识别、特征检测和视觉测量等下游任务的表现。正因如此，研发高效、稳定且自适应能力强的水下图像增强算法，已经变得相当紧迫。

早些年，一些优秀的增强算法相继出现，例如基于卷积神经网络的 Water-Net[2] 、UIE-Net [3]、基于对抗神经网络的 WaterGAN[4]以及基于视觉变换器（Vision Transformer, ViT）的增强网络[5]。它们能完成自动色偏校正、对比度拉升、细节增强等修复任务。然而，传统卷积架构在极端复杂水质下仍有局限，在应对非均匀全局色偏时，往往难以对局部细节保护和全局色彩一致性进行兼顾[6]。

近年来，水下图像增强技术受到广泛关注并快速发展，国内外学者提出了大量增强与复原方法。早期研究主要依赖直方图均衡化（Histogram Equalization，

HE），Zuiderveld 等[7] 进一步提出限制对比度自适应直方图均衡化（Contrast Limited Adaptive Histogram Equalization，CLAHE），Land 等[8] 则从颜色恒常性出发设计了 Retinex 技术，它们主要通过对像素分布进行调整来提升对比度。基于物理模型的方法尝试对成像机理进行反演，并对透射率、背景光和散射系数等参数进行估计，以恢复清晰图像。深度学习兴起之后，以 CNN 为核心的方法逐渐占据主流，通过端到端特征映射，画质得到了大幅优化。生成对抗网络（GAN）引入对抗损失，缓解了增强过程中细节丢失的问题，视觉真实感随之提升。Dosovitskiy 等[9] 提出的视觉变换器（ViT）为该领域打开了新的局面。它依靠多头自注意力（Multi-Head Self-Attention，MHSA）机制，弥补了卷积感受野受限、长距离依赖难以建模的固有不足，在应对全图一致性色偏和非均匀光照时优势因此变得十分突出。当前的技术走向已较为清晰：研究焦点从单纯的局部修复，转向局部细节与全局色彩的协同优化。

尽管技术路径日趋成熟，校正大尺度全局色偏的同时，高频纹理仍容易出现过度平滑或噪声放大，这道瓶颈尚未被打破。正因如此，将 CNN 的局部特征提取能力与 Transformer 的全局语境建模能力深度融合，进而构建混合增强网络，是高性能水下图像修复最有潜力的方向。

1.1.2 面临的问题和挑战

水下环境与陆地自然环境显著不同，水下图像的成像特点和退化机理更为复杂，质量退化主要源于水体对光线的物理作用。水下图像退化的核心成因可归纳为三点：光线在水中的衰减、散射与多次反射，以及不同波段衰减的差异。水中光线在不同深度衰减如图 1-1。

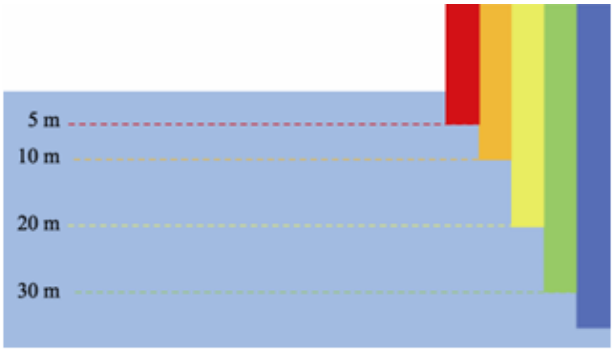


图 1-1 光照波段衰减

光线在水中传播时，被悬浮物、微生物和溶解性有机物持续吸收，亮度不断降低，画面偏暗，细节和纹理模糊，目标变得难以辨识。与此同时，悬浮微粒和气泡引起的散射与多次反射，会带来类似雾化的噪声，对比度大幅下降；反射还会对色彩分布造成扭曲，进而引发色偏和失真，使图像浑浊朦胧，如图 1-2。此外，水对光线的吸收和散射具有波长选择性。水分子及溶解物质对红、黄等长波的衰减远快于蓝、绿短波，这种不均衡衰减使水下图像呈现典型的蓝绿色偏[10]，色彩信息严重缺失，无法反映目标真实颜色状态，如图 1-3。



图 1-2 图像雾化



图 1-3 颜色失真

1.1.3 课题目的与意义

面对上述问题，图像处理工作首先需要恢复清晰度，去除噪声，同时纠正颜色失真。画质改善之后，各类水下作业才能得到稳定的视觉支撑。水下图像处理

技术一直在进步，但环境复杂、退化机理相互耦合，成像条件又不确定，现有方法很难同时兼顾增强效果、色彩保真度和细节完整性，真实场景中光照不均，水质多变，目标结构也很复杂，这些都进一步加大了增强难度。如何在动态环境下稳定、可靠且自适应地提升画质，是当前亟需解决的关键问题。

1.2 国内外研究现状

目前的水下图像增强方法，依据原理可划分为三类：基于物理模型的增强方法、基于图像处理的增强方法和基于深度学习的增强方法。水下环境复杂且特殊，水体对光线的散射和吸收作用显著，再加上水下光照不均、浑浊度差异大等因素，采集到的图像普遍存在色彩失真、对比度低、细节模糊、噪声明显等问题，严重制约了水下视觉任务的开展。本节综合国内外相关工作的调研结果，围绕各类方法的技术特点、应用场景和研究热点，对其发展现状与局限性作详细阐述。方法分类如图 1-4。

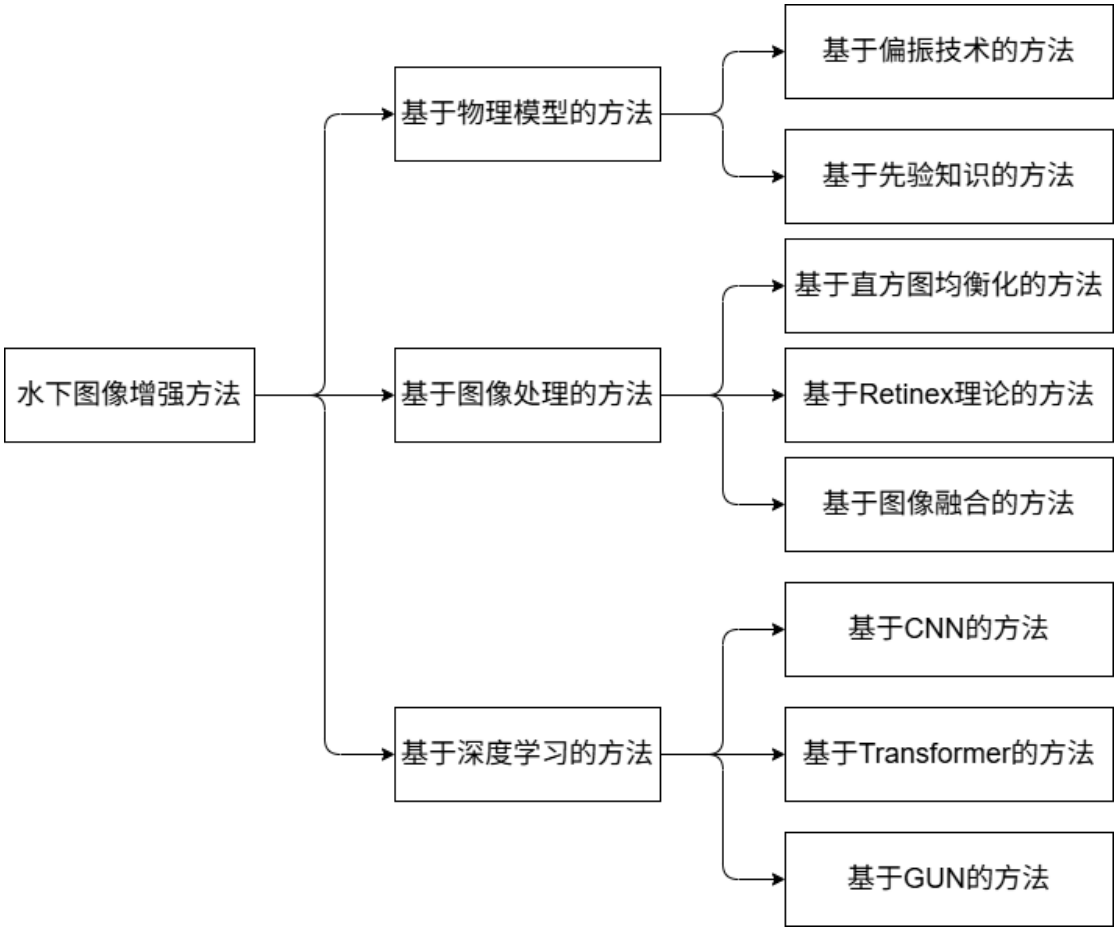


图 1-4 水下图像增强方法分类

1.2.1 基于物理模型的水下图像增强方法研究现状

物理模型方法的工作方式，是先建立一个尽量贴合实际的水下光学成像模型，用它来描述光线在水中的吸收、散射等传播过程，再借助数学推导和反演计算，一步步把原始图像信息还原出来，从而抵消水下环境造成的退化。这一类方法能否奏效，很大程度上取决于光学物理参数能不能被准确获取。参数获取的路径主要有两条，一是借助偏振成像技术，二是依靠先验知识推导，两条路各有侧重，适应的场景也不一样。

（1）偏振技术靠的正是光线自身的偏振特点。偏振相机先采集不同偏振方向的图像，再依据各方向上的强度差异和相位变化，把目标反射光与水体散射光剥离开来。散射干扰被针对性地抑制之后，图像的可见度和细节就能得到有效恢复。在珊瑚礁监测、水下生物观察这类场景相对固定的任务中，这种方法的优势尤其突出，目标的纹理和色彩特征都可以被清晰地还原出来。不过，该方法有明显的局限：性能高度依赖复杂的偏振成像设备，很难适配水下机器人自主巡航和大范围海域探测等自主作业场景，规模化普及与应用因此受限。

（2）基于先验知识的方法：先验知识方法受何恺明等[11] 提出的暗通道先验（Dark Channel Prior, DCP）启发，是当前的研究热点。其基本思想是利用自然图像中普遍存在的“暗通道”特性来构建透射率估计模型，再通过反演计算恢复图像的清晰度与色彩。近年来，国内外学者围绕 DCP 进行了大量改进，重点对透射率估计精度加以优化，并对背景光提取偏差进行修正，以提升方法的适应性。然而，先验方法仍然存在不足：在光照复杂（如有人工光源照射、水面反光强烈）或水体浑浊度较高的场景中，背景光强度和透射图等物理参数往往难以精确估计，复原结果容易出现色彩畸变、细节丢失或鲁棒性不够等问题，不容易适应水质和光照条件多变的复杂水下环境。

总体而言，基于物理模型的增强方法能够从本质上解释水下图像的退化机制，复原结果具有较好的物理合理性。但是，这类方法普遍需要用大量真实水下数据来校准物理参数，而不同水域的水体成分、浑浊度和光照条件差异很大，致使模型鲁棒性不足，跨场景稳定应用依然困难。

1.2.2 基于图像处理的水下图像增强方法研究现状

不同于物理模型方法，基于图像处理的方法不依赖复杂的水下光学成像模型，而是直接对像素值、色彩分布和灰度特征进行调整，进而改善对比度、饱和度以及视觉清晰度。这类方法结构简单、计算效率高，也不需要复杂的硬件支持，因此广泛用于对实时性要求较高的简单水下场景。根据技术思路，主要可分为以下三种方法：

（1）基于直方图均衡化（Histogram Equalization, HE）的方法：HE 方法通过调整像素强度概率分布，将原本过度集中的像素值重新均匀映射到整个灰度区间，从而扩大动态范围并提升对比度。其中的代表性工作是限制对比度自适应直方图均衡化（CLAHE）[7] 它将图像切分为多个子块，分别进行直方图均衡化，并对各子块的对比度增益加以限制，由此有效避免了传统 HE 容易出现的过度增强和噪声放大等问题。不过，这类算法仅关注灰度分布的调整，没有考虑水下图像不同色彩通道间衰减差异，处理极暗或严重色偏的图像时容易引起明显的色彩失真，出现偏红或偏蓝等现象，影响视觉质量。

（2）基于 Retinex 理论的方法[8]：Retinex 理论将图像分解为入射分量（表征环境光照）和反射分量（表征物体本身的真实特征）。基于颜色恒定性，该类算法对两个分量进行分离，并对入射分量加以偏差修正，以此消除光照不均带来的影响，提升对比度与细节清晰度。这些算法在改善对比度和抑制不均匀光照上效果显著，能够较好地还原物体的真实纹理，但因为主要聚焦于光影剥离，对水体散射引起的边缘模糊和细节丢失修复能力有限，难以从根本上解决水下图像的退化问题。

（3）基于图像融合的方法[12]：图像融合方法先对单张退化图像进行多种预处理，例如白平衡校色、对比度拉伸或噪声抑制，生成两张或多张各具优势特征的特征图，然后再通过设计合理的权重掩码进行融合，得到兼顾色彩、对比度和细节的增强结果。融合策略引入了白平衡、对比度增强等多尺度信息，能够较好地保持边缘清晰度并改善整体视觉。然而，这类方法也有明显不足：融合过程中局部区域容易出现过饱和，造成部分细节丢失；而且预处理步骤繁琐，需要设计多种策略并反复调参，计算成本偏高，不利于实时化应用，难以适配水下机器人

实时监测等场景。

总体来看，图像处理类方法算法简单、速度快、容易实现，可以快速提升水下图像的视觉质量。但本质上它们只是对像素值直接进行调整，没有深入考虑水下退化机制，增强过程中很容易放大噪声或引起色彩过度补偿，最终导致失真，难以应对复杂水下场景的高精度需求。

1.2.3 基于深度学习的水下图像增强方法研究现状

深度学习技术的快速迭代，让基于学习的水下增强方法凭借强大的特征提取与拟合能力，迅速占据了主流地位[13]。神经网络搭建好之后，依靠大量标注数据训练，模型就能自行摸索出水下退化的规律和增强映射关系，进而直接生成高质量图像。依照网络结构的差异，当前的研究大致沿着三个方向展开：

（1）基于卷积神经网络（CNN）的多路特征融合：卷积神经网络擅长提取局部特征，对细节和纹理的捕捉能力尤其突出，因此在水下图像增强任务中应用很广。这一方向的典型工作是 Water-Net[2]，它首次将 CNN 运用在水下图像增强方面，展示了 CNN 在水下图像增强的潜力。通过这种方法得到的增强图像，在亮度恢复与对比度提升上表现稳定，但色彩一致性与全局色偏校正仍有提升空间。

针对单一色彩空间信息不足的问题，Wang 等[14]人提出 UIEC^2-Net，首次在水下图像增强中同时使用 RGB 与 HSV 双色彩空间，通过像素级校正、全局亮度饱和度调整和注意力融合，让色彩恢复更自然，也提升了模型对亮度、饱和度的敏感度，为多色彩空间融合增强提供了重要思路。Afzal 等[15]人近期提出的 CNN-CECA 方法进一步拓展了这类思路，在 ResNet-50 基础上引入多色彩空间非线性曲线估计，结合 RGB、HSV、CIELab 三个空间的多项式、Sigmoid 与指数映射，显著提升了色彩恢复的自然度与可解释性。

李云、孙山林等[16] 提出的多路混合注意力网络，设置了直方图均衡、伽马校正和白平衡三条独立分支，分别负责提取对比度特征和色彩特征，之后通过注意力机制将多路信息融合起来，实现精准增强，色偏和对比度不足的问题由此得到改善。路斯棋等[6] 则提出双阶段策略：第一阶段校正色偏，第二阶段修复细节模糊，分步解决降质问题，提高了增强结果的稳定性。这类 CNN 多路融合方法的优点是参数利用率高、细节提取能力强，但 CNN 感受野有限，对全局信息的

感知较弱，因而很难有效应对水下图像全局性的色偏和整体退化。

（2）Transformer 与 CNN 并行引导：水下环境普遍存在全局色偏和光照不均，而 Transformer 因其长距离依赖建模能力，恰好能有效捕捉全局特征，因此近年来 Transformer 与 CNN 并行引导的策略成为研究热点。常戬等[17] 借助 3D 位置嵌入与 Transformer 提取全局色彩和光照特征，先用 CNN 提取局部细节，再经过特征融合实现全局与局部的协同增强，有效改善了全局色偏。王德兴等[18] 在此基础上增加了细节锐化模块，进一步提升了图像边缘的清晰度和纹理细节。Fan Lu 等[19] 提出的 Scale-patch Synergy Transformer 优化了局部与全局的协同机制，通过多尺度 patch 划分和特征交互，能够兼顾全局色彩校正和局部细节修复，对复杂水下场景的适配能力更强。

Yang 等[20]人针对水下增强场景提出的 ESRTGAN 同样采用了 CNN 与 Transformer 结合的思路，依靠局部特征提取与全局上下文建模的互补优势，配合多尺度特征融合与自适应通道注意力，在斑点噪声抑制、边缘保留和结构复原上表现突出，特别适合这类对细节精度要求高的场景。Qiao 等[21]人提出的 Transformer-CNN 混合网络直接在编码器与解码器中使用混合卷积与 Transformer 模块（MCTB），同时强化细节提取与全局建模能力，并在跳跃连接中加入增强特征融合模块（EFFM），进一步优化色彩与结构信息的表达，在多项测试集上均取得了更稳定的增强效果。

（3）生成对抗网络（Generative Adversarial Network，GAN）的应用：GAN 由生成器和判别器构成。两者通过对抗训练相互博弈，使得生成的图像在逼真度上往往很高，增强任务里，它在生成真实纹理、修复细节方面尤为突出。不过，传统 GAN 用到水下增强时，训练不稳定、模式崩溃、细节模糊等问题频频出现。

FUnIE-GAN[22]是该方向极具代表性的实时增强模型，生成器采用轻量型 U-Net 结构，配合跳跃连接保留细节，兼顾推理速度与视觉效果，但其鲜艳度偏高，易出现色调扭曲与边缘虚化。

Li 等[23]人提出的 SER-GAN 进一步优化了 GAN 在水下增强中的表现，网络以空间增强残差模块、分层注意力密集聚合模块与特征增强桥接模块为核心，分别针对色彩失真、对比度低、细节模糊三类问题进行专项优化，能够更好地聚

焦关键区域并强化边缘纹理，在公开数据集上使 PSNR、SSIM、UIQM 等指标获得稳定提升。

郭迪[24] 针对这些问题设计了双路注意力 GAN，加入多尺度特征交互模块和注意力机制之后，生成器能更准确地抓住退化特征，训练不稳定和细节丢失的状况因此得到了明显改善，输出图像的色彩更自然，细节也更丰富。

综上所述，基于深度学习的方法已经占据了主流。这类方法对退化规律的把握更为精细，色彩与纹理细节因此得到明显改善，面对复杂水下场景时，适配能力也更强。不过，挑战并没有消失。网络结构变得越来越复杂，训练高度依赖大量标注数据，成本高、周期也长。同时，复杂模型对算力的消耗极大，高性能 GPU 几乎成为标配，想部署到算力有限的水下嵌入式设备上相当困难，模型复杂度与实时性之间的矛盾，让轻量化部署仍面临不小制约。

1.3 论文的主要内容与结构

1.3.1 论文主要内容

（1）对水下图像退化机理及现有方法的不足进行分析，进而确定混合架构增强方案；

（2）完成 HUENet 网络的设计工作，搭建 CNN 与 Transformer 结合的 U 型结构；

（3）构建混合损失函数，对色彩、结构及细节进行多约束优化；

（4）开展模型训练、测试与对比实验，以验证算法的有效性；

1.3.2 论文主要结构

论文的主要组织结构安排如下：

第一章首先对水下视觉系统面临的成像退化挑战与技术发展趋势进行介绍，并对课题的研究背景、目的及意义作出分析。随后，对国内外在传统算法与深度学习领域的相关研究工作加以概述，并交代论文的主要研究内容及结构安排。

第二章先对水下图像的光学模型及质量下降的原因进行阐述，再对基于深度学习的增强算法（包括卷积神经网络和注意力机制）作介绍，最后说明水下图像增强的评价指标。

第三章以 HUENet 架构为研究对象，对基于残差块与视觉变换器块的协同设计策略进行描述，并建立对称 U 型编码-解码模型，对特征提取流、瓶颈层注意力分布以及复合损失函数约束模块进行定量设计。

第四章对算法核心模块与演示系统的具体实现进行详细描述。借助预处理过滤器来完成图像尺寸对齐与数据增强。除 PyTorch 代码实现外，还对基于 Streamlit 的演示系统模块构建加以说明，涵盖数据集管理预览、批量推理评测及统计报表生成等模块的逻辑。

第五章呈现系统功能测试与算法性能评估的结果。利用 UIEB 等测试集进行批量测试，对 PSNR、SSIM 和 UCIQE 等关键指标作了对比，展示演示系统交互界面，通过视觉效果图对 HUENet 算法的优越性加以分析，还进行消融实验。

第六章对论文所完成的研究工作进行总结，指出当前系统在极端复杂场景下存在的不足，并规划下一步的优化方向，展望水下智能视觉技术的前景。

2 基本理论

本章从水下光学成像的物理机理入手，分析光线在水体传输中的选择性衰减与散射模型。然后分析不同深度学习框架的优缺点，确立最终方案。最后，对衡量水下图像增强质量的主客观评价指标进行系统说明，为后续算法设计与验证提供理论依据。

2.1 水下光学成像物理模型

水下环境与陆地大气截然不同。光线在水下传输时受到水体介质的强烈干扰，成像质量因此严重退化。

光在水中传播时，水分子、溶解有机物及悬浮微粒会吸收光子能量，光强便随距离呈指数衰减，这种吸收对于不同波长的衰减率差异很大。红光在水下 5 至 10 米深处基本已被完全吸收，拥有更强的穿透力蓝、绿光则能传播到超过 30 米深。光谱能量分布的这种不平衡，正是水下图像呈现蓝绿色偏的根本原因。

散射主要由海洋雪、泥沙等悬浮微粒引起，分为前向散射与后向散射。前向散射是光线到达目标后偏离原方向，造成边缘模糊与对比度下降。后向散射则是环境光尚未到达目标，便被微粒反射进入传感器，形成叠加的“雾化”效应，严重掩盖目标纹理。

在水下视觉研究广泛采用 Jaffe-McGlamery 物理模型[25]来描述退化过程，如图 2-1。该模型将传感器接收到的总能量 E_T 简化为三个分量的线性之和：

（1） 直接分量 E_d：目标表面反射光经水体衰减后直接到达传感器的部分。

（2） 前向散射分量 E_b：目标反射光在传输中经小角度散射后的部分。

（3） 后向散射分量 E_f：背景环境光经水体介质散射后进入传感器的部分。

传感器收到的总能量 E_T 在模型中可表示为：

$$E_T = E_d + E_b + E_r \tag{2-1}$$

图像修复的核心目标，就是通过算法估计退化参数，反演出无失真的原始目

标辐射能量。

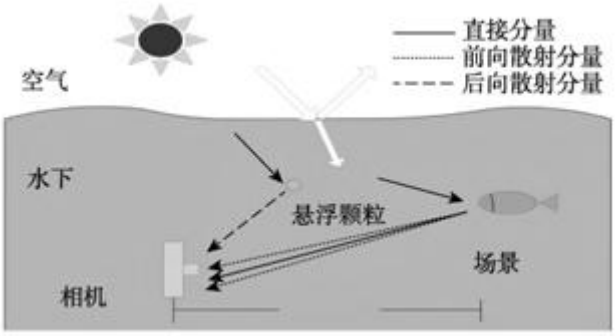


图 2-1 水下图像成型模型

2.2 水下图像增强技术方案对比与确立

在深度学习研究范畴内，现有水下图像增强技术包含多种网络架构。为合理确定本文模型结构，本节依次分析纯卷积网络、生成对抗网络以及视觉变换器的技术特性与适用局限，结合水下复杂退化环境确立最终方案，论证本文 HUENet 采用 CNN-Transformer 混合架构的科学性与合理性。

2.2.1 纯卷积神经网络方案的局限性

卷积神经网络（CNN）凭借局部感受野和权重共享，一直在视觉任务里占着主导地位。卷积算子通过滑动窗口捕获空间特征，对于边缘、纹理这类高频细节，具有很高的提取效率。本设计所采用的 ResBlock 结构里加了残差学习，这一设计提升了对于边缘特征的学习，使图像细节更完善。然而，水下图像的退化光谱衰减往往是大尺度、全局性的，这种全局色偏对于卷积神经网络难以处理，这要求模型具备长距离的依赖建模能力。纯卷积架构的卷积核尺寸是固定的，面对整张图的色调校正，视野先天受限，若通过盲目增加深度来扩大感受野，则容易引发计算冗余或导致局部特征的过度平滑。

2.2.2 生成对抗网络方案的风险分析

生成对抗网络（GAN）在图像风格迁移任务中表现出的视觉真实性一度使其成为水下修复的热门选项。通过生成器与判别器的博弈，GAN 能够合成鲜艳的纹理信息，但对抗训练机制本身并不稳定，模式崩溃或随机伪影的产生常导致增强后的图像偏离真实的物理场景，出现不正常的条纹或者色斑。这对于需要高精

度、高保真视觉感知数据的海洋探测任务而言并不稳定，具有不可控的技术风险，难以作为稳健的底层算法方案。

2.2.3 视觉变换器与混合架构的技术优势

视觉变换器（Vision Transformer, ViT）的兴起为解决全局色偏提出了一条新路径。其核心的多头自注意力机制（MHSA）能够直接计算空间中任意两个像素点之间的相关性，这种突破距离限制的建模能力使其在识别并修正光谱衰减上具有显著优势。然而，Transformer 的计算开销与像素数量呈平方关系增长，直接在原始分辨率下运行会造成严峻的显存负担。同时，由于缺乏卷积算子所具备的平移不变性等空间先验，该架构在处理细微局部纹理时，其感知精度往往略逊于深度卷积网络。

2.2.4 设计方案的选择与 HUENet 的技术特点

基于对上文各类深度学习架构在水下增强任务中表现的深入论证，最终确立了以“CNN 局部特征捕捉”与“Transformer 全局语境建模”为核心的混合双分支设计方案，作为 HUENet 网络的核心技术逻辑。该方案的设计初衷在于利用不同网络结构的功能互补，在统一的 U 型对称架构中实现退化特征的精准修复，兼顾全局与细节。

HUENet 首先在编解码两端均嵌入了大量集成残差结构的卷积算子，来解决细节方面。残差路径的引入，使得微观细节在多尺度变换过程中得到完整保留，有效规避了传统算法中常见的边缘模糊现象。对于最具挑战性的非线性色偏，选择在信息密度最低的瓶颈层部署视觉变换器模块。选择将自注意力操作限制在经过二次下采样压缩后的低分辨率特征维度内，就能以较低的算力成本建立长程特征依赖，从而避开了高分辨率下的计算瓶颈，实现对全图背景光分布的精准建模。最后通过跳跃连接把浅层物理细节和瓶颈层校正过的宏观语义，在通道上拼到一起。这种"全局调色、局部修形"的协作方式，给了 HUENet 很强的场景自适应能力。既能提升图像的通透性，又能够保留纹理细节。

2.3 水下图像质量评价指标

图像质量评价（Image Quality Assessment, IQA）作为衡量增强算法优劣的核

心基准，既能对模型性能进行量化，也可以为参数调优提供反馈。水下图像的评价方法大体分为主观评价与客观评价两类。

主观评价依赖观察者的直觉感受，让受试人员对色调、清晰度和细节还原度进行打分。这种方法虽最贴合人类视觉系统（Human Visual System, HVS）的真实感知，但在深度学习带来的大规模实验数据面前，人力处理数据的能力较弱，并且人力成本贵、标注需要的时间长，还有受个体差异干扰，因此，在实际研究中，客观指标凭是更主流的选择。

客观指具有计算高效、结果稳定、可复现性强的优势。根据是否依赖高质量参考图像（Ground Truth），又划分为参考性评测（全参考）与非参考性评测（无参考）。

2.3.1 参考性评测

参考性评测主要用于具备理想参考图像的数据集，来验证算法性能。它通过计算增强图像与真值图之间的数学偏差，反映像素还原和结构保持方面的精度。

（1） 均方误差（MSE）

均方误差（Mean Squared Error, MSE）是评估像素差异的基础指标，其通过计算被处理图像 K 与参考图像 I 对应像素点之间差值的平方均值来衡量失真程度。MSE 数值越低，说明增强结果与参考图在灰度分布上越接近。

$$\mathrm{MSE}=\frac{1}{\mathrm{H}\times\mathrm{W}\times\mathrm{C}}\sum_{i=1}^{H}\sum_{j=1}^{W}\sum_{k=1}^{C}(\mathrm{K(i,j,k)}-\mathrm{I(i,j,k)})^2 \tag{2-2}$$

其中，H、W、C 分别表示图像的高度、宽度和通道数；K(i,j,k) 为增强图像像素值，I(i,j,k)为参考图像像素值。

（2） 峰值信噪比（PSNR）

峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）是衡量图像还原质量最常用的指标之一。它基于 MSE 进行对数变换，表征信号峰值功率与噪声功率的比率。PSNR 数值越高，代表图像的像素级失真越小，对于滤除水下噪声的效果评估具有重要参考意义。

$$\mathrm{PSNR}=10\log_{10}\left(\frac{2^n-1}{\mathrm{MSE}}\right)^2 \tag{2-3}$$

其中，n 为图像像素位深，通常取 8，即像素值范围为 0~255。

（3） 结构相似性（SSIM）

由于 PSNR 仅关注像素强度的差异，往往无法准确捕捉人类对图像结构的感知。结构相似性（Structural Similarity Index, SSIM）[26]通过综合考虑亮度、对比度和结构三个属性的关联，评估图像的保真度。SSIM 取值范围为 [0, 1]，数值越接近 1，说明增强后的水下物体轮廓及纹理特征保留得越完整。

$$\mathrm{SSIM}(x,y)=\frac{(2\mu_x\mu_y+c_1)(2\sigma_{xy}+c_2)}{(\mu_x^2+\mu_y^2+c_1)(\sigma_x^2+\sigma_y^2+c_2)} \tag{2-4}$$

其中 μ_x,μ_y 分别为两幅图像的均值；σ_x,σ_y 分别为两幅图像的方差；σ_{xy} 为两幅图像的协方差；c_1,c_2 为常数，维持计算稳定。

2.3.2 非参考性评测

在实际水下作业任务中，往往难以获取对应的清晰参考图像，因此非参考性评测指标具有极强的工程应用价值。此类指标通过提取图像自身的统计特征，直接对视觉感官质量进行量化评价。

（1） 水下图像质量指标（Underwater Image Quality Measure,UIQM）

UIQM 指标[27]针对水下成像的退化机理，将评估过程分解为色彩度量（UICM）、清晰度度量（UISM）和对比度度量（UIConM）三个分量。通过对不同维度进行加权求和，UIQM 能够全面地衡量算法在色偏校正、边缘锐化以及视觉透明度提升方面的综合性能，分值越高代表图像的整体视觉美感越强。

$$UIQM = c_1 \times UICM + c_2 \times UISM + c_3 \times UIConM \tag{2-5}$$

根据经典文献设置，加权系数通常取值为 c1=0.0282，c2=0.2953,c3=3.5753。

（2） 水下色彩质量指标（Underwater Color Image Quality Evaluation,UCIQE）

UCIQE 指标[28]是专门用于衡量水下图像色彩平衡能力的无参考指标。它通过统计图像在 Lab 色彩空间下的色度标准差、亮度对比度及平均饱和度，反映图像色调的均衡性。该指标能够有效辨别增强过程是否引入了过饱和或伪影现象。

$$UCIQE = c_1 \times \sigma_c + c_2 \times con_i + c_3 \times \mu_c \tag{2-6}$$

其中：σc 为色度 (Chroma) 的标准差，反映色彩的丰富度；conl 为亮度的对比度 (Luminance Contrast)，反映图像的通透感；μc 为色度的平均值，反映色

彩的饱和度。加权系数通常取值为 c1=0.4662，c2=0.2745，c3=0.2593。

2.4 Streamlit 交互式应用框架

深度学习研究里，算法的工程化展示与自动化评测是验证成果的重要一环。本研究利用 Streamlit 框架，搭建了一套集成化的水下图像增强演示系统，下面介绍其基本原理及部署中的技术优势。

2.4.1 Streamlit 框架概述

Streamlit 是一款基于 Python 的开源 Web 框架，主要面向机器学习和数据科学。与 Django、Flask 等传统框架不同，它采用响应式编程模型，开发者只需编写纯 Python 脚本，无须 HTML、CSS 或 JavaScript，即可构建高性能的交互界面。其核心机制是对 Python 代码逻辑与前端 UI 组件进行深度绑定：当用户操作滑动条、按钮或文件上传器等交互控件时，框架自动重新运行脚本并局部更新视图。这种模式大幅缩短了从模型原型到可视化平台的转化周期，如图 2-2。

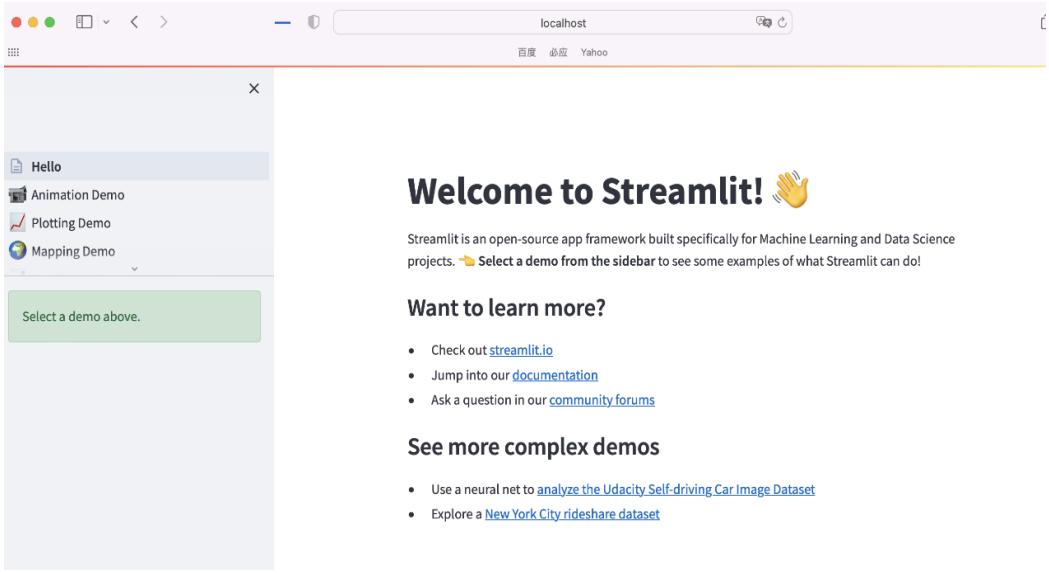


图 2-2 Streamlit

2.4.2 交互式组件与数据流逻辑

演示系统的交互逻辑建立在 Streamlit 的组件库之上。st.sidebar 构建了参数控制面板，支持用户在线切换不同的预训练权重文件。st.file_uploader 模块负责接收异构格式的水下图像输入。在数据流转上，上传的二进制图像经 Pillow 解码后转换成 PyTorch 张量，再由 HUENet 进行处理，结果实时渲染到前端页面。

这种“输入—处理—展示”的闭环，使非专业用户也能直观评判色彩校正和细节增强的实际效果。

2.5 本章小结

本章为水下图像增强算法的设计提供了一套理论蓝图。先从水下光谱的选择性衰减和 Jaffe-McGlamery 成像模型入手，分析了图像退化的物理本质。随后分别梳理了卷积神经网络在局部特征提取上的能力，以及视觉变换器的全局建模优势。在此基础上，建立起一套包含全参考指标（PSNR、SSIM）与无参考指标（UIQM、UCIQE）在内的多维质量评估体系，为接下来 HUENet 增强系统的设计与实现提供理论基础。还介绍了演示系统实现所依托的 Streamlit 框架，为具体实现做了技术论证。

3 HUENet 算法设计

本章详细阐述了混合注意力 U 型增强网络（Hybrid attention U-shaped underwater Enhancement Network, HUENet）的设计方案。先根据水下图像退化特征明确算法功能需求，再展示总体设计架构，并对对称式 U 型编码-解码结构以及卷积与注意力机制的双分支协作逻辑进行描述。最后，对算法核心功能模块及复合损失函数作深入推导与设计。

3.1 功能需求

水体对光线的选择性吸收和强烈散射，既造成光谱波段非线性偏移，也使图像在空间上呈现明显的雾化感，局部特征分布失衡。

针对上述瓶颈，本章设计并实现了一种混合注意力 U 型增强网络（HUENet）[29]。算法核心在于融合卷积神经网络（CNN）的局部纹理捕获能力与视觉变换器的全局长程建模能力。主干基于改进的编解码结构，编码阶段引入残差学习机制来保留高频细节，瓶颈层则嵌入全局自注意力模块，以修正大尺度色偏。与传统多步处理方法相比，HUENet 能够实现从原始退化图像到清晰图像的端到端映射，大幅降低计算开销与实现复杂度。实验分析表明，该算法在处理复杂退化场景时特征恢复能力突出，工程应用潜力较强。

3.2 网络框架

HUENet 增强算法用一个统一的网络框架，同时处理水下图像的局部特征退化与全局光谱畸变。总体架构采用了对称式的 U 型编码-解码结构（U-shaped Encoder-Decoder Architecture），同时还融入了视觉变换器的全局建模机制。这种设计既能有效保留图像精细纹理，又能够在低分辨率特征空间中捕捉宏观的光照依赖关系。图 3-1 展示了 HUENet 的详细网络结构。

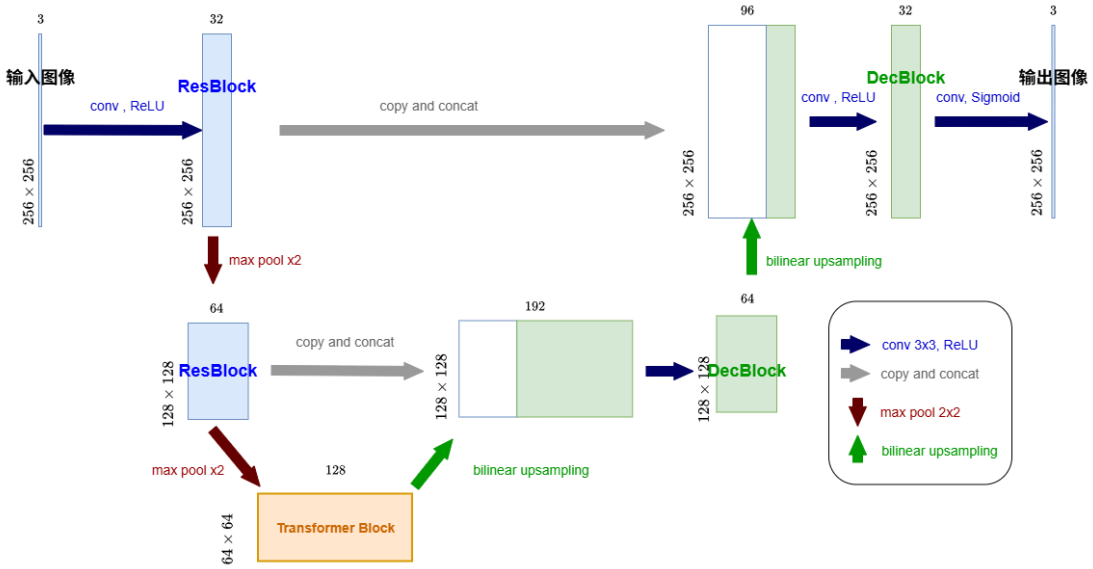


图 3-1 HUENet 网络结构图

系统的处理流程如下：输入为一张被归一化到 256×256 尺寸的失真水下图像，进入网络，先经过初始卷积层，将 3 通道 RGB 信息映射到 32 通道的高维特征空间，完成基础表征的建立。然后进入编码阶段，层级化的残差块（ResBlock）对图像进行下采样，在压缩空间分辨率的同时增加特征通道数，从而捕获多尺度的局部结构信息。随后来到网络最底部的瓶颈层，此处感受野最大，这里部署了基于多头自注意力机制的视觉变换器块，负责对全图光照分布和背景色偏作出宏观建模。然后进入解码阶段，双线性插值上采样逐步恢复图像分辨率，并通过跳跃连接（Skip Connection）将编码器捕获的浅层纹理与解码器的深层语义进行融合。最后，输出层把融合后的特征映射回标准像素空间，输出 256×256 尺寸的增强图像。各组件的详细设计逻辑与损失函数构造见下文。

3.3 功能模块设计

3.3.1 特征提取单元（ResBlock）

在水下环境中，物体的边缘纹理极易受到散射噪声的干扰而变得模糊。为了提取深度神经网络中的高频特征，算法采用了基于残差连接的特征提取单元（ResBlock），结构如图 3-2 所示。

ResBlock 的做法和传统卷积不同，它靠恒等映射来应对深层网络里梯度消失和表征退化的问题。单元内部是两层 3×3 卷积，每层卷积后面依次跟批归一化和 ReLU-BN 来稳固各层特征图的数值分布，加速收敛；ReLU 则引入非线性防止梯度消失。输入 x 与经过两次卷积后得到的特征图逐元素相加，网络由此只需盯住输入和目标清晰图像之间的残差去学。这一设计对珊瑚、岩石等复杂背景中精细纹理的保留帮助很大。

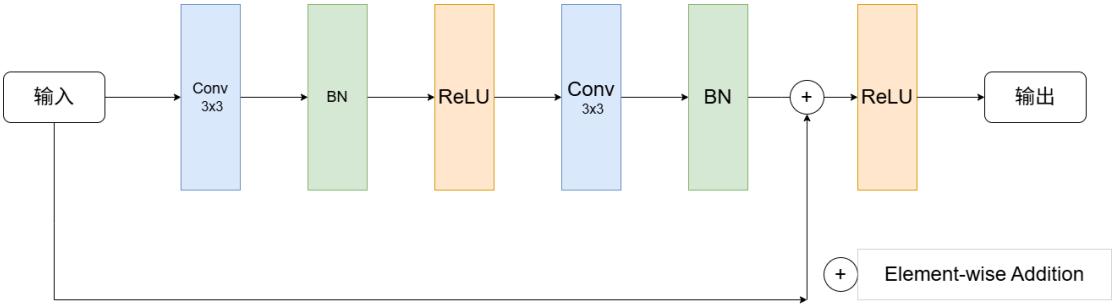


图 3-2　ResBlock 结构图

3.3.2　视觉变换器块（Vision Transformer Block）

大尺度色偏校正需要依赖全局特征，因此系统在 U 型架构的瓶颈层部署了视觉变换器块（Vision Transformer Block）。该模块能够借助非局部建模能力，跨越空间距离来捕捉全局环境信息。Vision Transformer Block 的内部逻辑结构如图 3-3 所示。

模块的特征处理分为两个核心子阶段，每个阶段均采用残差结构保证信息有效传递。

首先是全局依赖建模阶段。特征图进入模块后经过层归一化（Layer Normalization, LN）处理。与 CNN 中常用的批归一化不同，层归一化能稳定单个样本内部的特征分布，为后续注意力计算提供归一化的数值基准。接着，特征流进入核心的多头自注意力机制（Multi-Head Attention, MHA）层，结构如图 3-4。特征图被映射为查询（Query）、键（Key）和值（Value）向量，通过计算像素点两两之间的点积相似度，模型识别出全图中受光照衰减影响相近的区域，由此实现全局背景光与色偏的统一感知。为保留原始特征信息，该阶段采用第一次跳跃连接，将 MHA 输出与模块初始输入进行逐元素相加。

之后是非线性特征映射阶段。建立全局联系后，特征流再次经层归一化，进

入多层感知机（Multi-Layer Perceptron, MLP）子层。MLP 由两个全连接层及中间的 GELU 激活函数组成，功能是对注意力捕捉到的特征进行高维非线性变换与融合，进一步增强语义表达能力。MLP 末端设计了第二次跳跃连接，将处理后的特征与该阶段输入逐元素相加。

这种双重残差结构使 Vision Transformer Block 能有效捕获水下图像的长程依赖，同时避免深度增加带来的特征退化。低分辨率瓶颈层应用该模块后，系统在较低计算复杂度下，全局光影分布的校正能力显著增强。

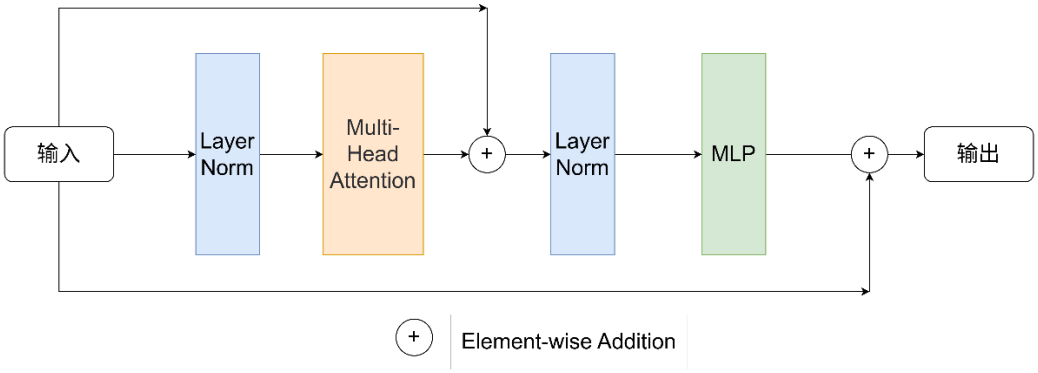


图 3-3 Vision Transformer Block 结构图

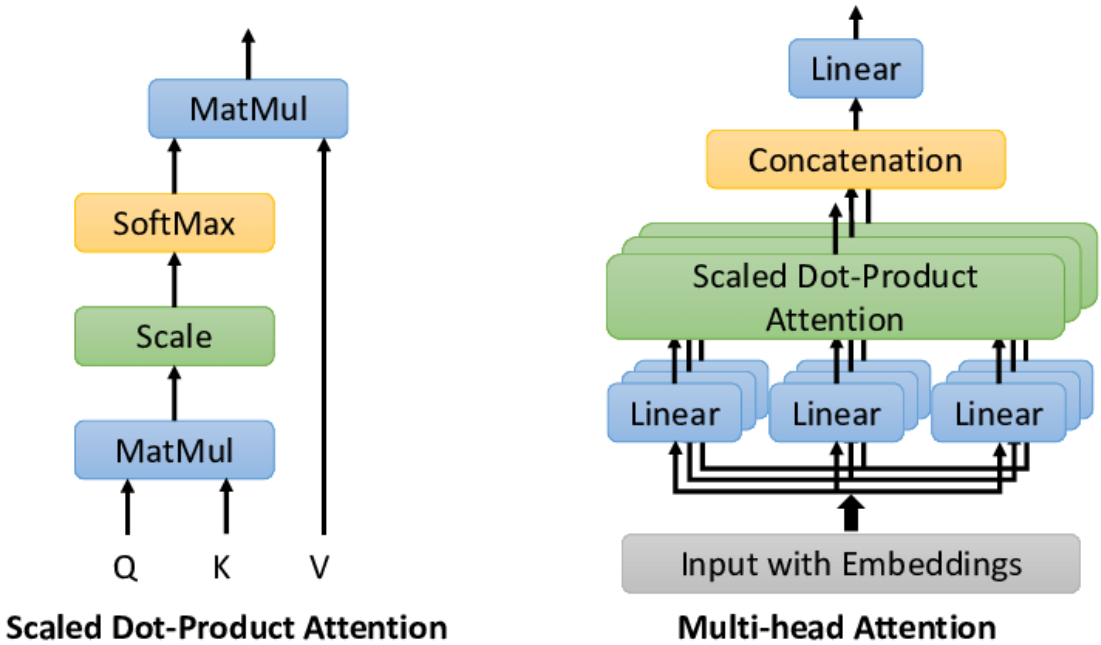


图 3-4 Multi-Head Attention 结构图

3.3.3 跳跃连接（Skip Connection）

对称式 U 型网络中，编码阶段的连续下采样与池化虽然能提取抽象语义，但也会导致不可避免的局部细节永久性丢失。为此，系统设计了基于跳跃连接（Skip Connection）的特征融合机制，来缓解水下目标细节恢复不完整的问题。该模块的功能逻辑如图 3-5 所示。

跳跃连接模块的执行围绕两个核心步骤展开：先把来自不同空间维度的特征拼在一起，再对齐通道并消化融合信息。多空间维度特征拼接步骤中，特征融合模块同时接收来自对称编码层级的局部特征图和下一级解码器的上采样特征图。其中上采样特征图具备较好的色彩感知与宏观结构，但空间轮廓相对模糊；而编码器特征图则保留了图像中高频的边缘拓扑信息。系统利用通道拼接（Concatenation）算子将两者在通道维度上堆叠起来，同时保留两者的特征，这种方法能够有效弥补深层卷积路径在信息传递中的特征稀疏。

通道对齐与特征消化，为的是统一维度，并进一步提纯融合后的特征。拼接之后，特征张量的通道数翻倍，系统在这里引入一个 1×1 卷积来执行通道重映射。这个操作会动态调整两路特征各自的权重贡献，使得编码器特征里混入的背景散射噪声被压制，而目标物体的纹理表达则得到强化。对齐后的特征流随后送入解码器后续的残差块做深度消化，增强图像在边缘交界处的过渡也就更自然。

跳跃连接的引入，使 HUENet 可将瓶颈层提取的“全局色偏校正信息”与编码阶段保留的“局部结构信息”深度互补。实验数据证实，这一设计对提升结构相似性（SSIM）指标表现有显著作用。

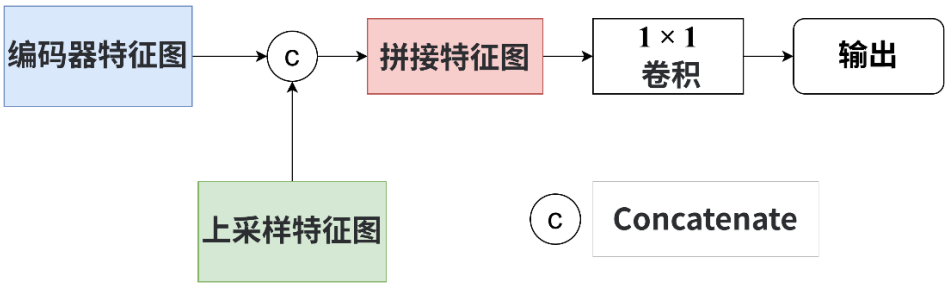


图 3-5 跳跃连接

3.4 复合损失函数设计

水下图像对比度低，结构纹理模糊，退化特征明显，单一的像素级损失往往会造成边缘平滑或结构失真。针对水下图像对比度低且结构纹理模糊的特点，系统设计了一种由像素损失L_1与结构相似度损失L_{SSIM}构成的复合损失函数L_{Total}，兼顾图像的像素还原精度与人眼感知的结构保真度。

3.4.1 平均绝对误差损失 L_1

为了让增强图像在像素数值上与参考图像高度一致，系统引入了 L1 损失（即平均绝对误差，MAE）。相比均方误差（MSE），L1 对离群值没那么敏感，遇到水下图像里那种悬浮颗粒噪声时，它具有更好的稳健性，能够生成边缘更加锐利的图像。其数学定义如下：

$$L_{L_1} = \frac{1}{\mathrm{H\times W\times C}}\sum_{i=1}^{H}\sum_{j=1}^{W}\sum_{k=1}^{C}(I_{pred}(\mathrm{i,j,k}) - I_{gt}(\mathrm{i,j,k}))^2 \tag{3-1}$$

其中，H、W、C 分别表示图像的高度、宽度和通道数；I_{pred} 为增强图像像素值，I_{gt}为参考图像像素值。

3.4.2 结构相似度损失 L_{SSIM}

像素级损失盯的是局部数值是否接近，图像的拓扑结构和对比度分布就容易被忽略。为把水下目标的轮廓信息保护好，系统额外引入了基于 SSIM 的结构约束。SSIM 指标通过对比亮度、对比度和结构来评估两幅图像的相似程度。训练时，网络被 1−SSIM 这项损失来使网络去学习全局的结构特征。其计算公式为：

$$L_{SSIM} = 1 - SSIM(I_{pred},\ I_{gt}) \tag{3-2}$$

其中，SSIM 的定义如下：

$$\mathrm{SSIM(x,y)} = \frac{(2\mu_x\mu_y+c_1)(2\sigma_{xy}+c_2)}{(\mu_x^2+\mu_y^2+c_1)(\sigma_x^2+\sigma_y^2+c_2)} \tag{3-3}$$

式中，μ_x,μ_y 分别为两幅图像的均值；σ_x,σ_y 分别为两幅图像的方差；σ_{xy} 为两幅图像的协方差；c_1,c_2 为常数，维持计算稳定。

3.4.3 总加权损失函数

为了色彩细节与全局结构上的平衡，系统将上述两项损失进行了线性加权融合。根据实验调优结果，权重最终定成了 1:1 的等权重分配。总损失函数 L_{Total} 定义如下：

$$L_{Total} = \alpha L_{L_1} + \beta L_{SSIM} \tag{3-4}$$

根据训练代码实现，取权重系数 α =0.5, β =0.5。该复合约束机制确保了网络在迭代过程中能够同时优化色彩分布的准确性与目标轮廓的清晰度。

3.5 本章小结

本章围绕 HUENet 的架构设计展开了详细论述。在对称式 U 型编码—解码框架下，先确立了残差卷积分支与视觉变换器全局分支的协作模式。接着，紧扣水下图像的特征恢复需求，分别完成了残差学习特征提取模块和具备长程建模能力的瓶颈层模块的设计工作。最后，从像素精确度和结构完整性两个维度综合考虑，推导并最终敲定了 1:1 的复合损失函数。整套架构设计与约束逻辑，为后面算法的代码实现和实验验证提供了核心理论依据。

4 HUENet 增强算法与演示系统实现

本章主要围绕算法开发与演示系统实现两大方面展开，把数据预处理、核心模块编码和交互系统搭建整合为一套完整的方案。首先交代实验所用的混合数据集的构成和预处理的标准，为模型训练提供多样化的输入基准；随后，从代码构建的技术细节出发，逐一介绍残差卷积算子、视觉变换器块以及 U 型架构在 PyTorch 框架下的具体实现，说明各模块的功能定位与技术优势；最后，展示了基于 Streamlit 框架的演示系统，通过数据集管理、实时对比演示和批量性能评测三大模块，使得模型从代码脚本转化为可直观操作的软件工具，为后续性能测试与学术验证提供可靠支撑。

4.1 数据预处理

水下场景多变，如果训练数据只局限于某一种水质或光照，在陌生环境模型很容易里表现失常。同时，真实水下成对数据获取成本高、数量也有限，单靠真实图像很难实现退化模式的全覆盖。针对上述问题，系统基于 PyTorch 框架搭建了一条自动化、标准化的处理流水线。通过自定义 CombinedDataset 类，对多源异构水下数据集进行混合加载、格式统一与动态增强，为 HUENet 的高效训练提供了规范可靠的基准，这种处理能够解决传统处理中人工操作繁琐、格式不一、利用率低的问题。

真实部分选用 UIEB 数据集，提供了 890 组涵盖不同水质、光照和场景的水下图像，每一组都有对应的清晰参考图。这些数据能直观反映真实水体中的退化特性。为了在训练中持续跟踪模型状态，我们将这 890 组图像按 9∶1 拆分为 800 组训练样本和 90 组验证样本——训练集用于参数更新，验证集用于实时观测收敛趋势，以便及时调整超参数，防止过拟合或欠拟合。

合成部分则引入 EUVB 大规模数据集，它通过模拟浑浊度、光衰减等水下条件，生成了数千组退化图像。实验时我们从中筛选出 3700 组特征差异明显的配对样本，动态混入训练过程。合成图像和真实场景虽然有差距，却能显著拓宽特征空间，尤其是能够让模型在极端浑浊或非均匀光照条件下学会更稳定的修复

行为。

在代码层面，数据预处理被设计成一条模块化流水线，各步骤职责清晰，便于以后扩展或替换。系统先用 os.path 自动遍历数据集根目录，再用 sorted 对文件名做全局排序，确保退化图和参考图严格对应。加载图像时，OpenCV 和 PIL 协同工作，强制转到 RGB 色彩空间，以此来消除 Alpha 通道可能带来的维度异常，让输入张量统一成 3×H×W。尺寸方面，PyTorch 的 Resize 算子把所有图像缩放到 256×256。这个分辨率既留得住足够的纹理细节，又不会在批处理时给显存造成压力，避开了尺寸不一致导致的显存溢出或计算效率骤降。最后将素值从[0,255]归一化到[0,1]，环境光绝对亮度差异对梯度更新的干扰被削弱，模型的注意力就能更集中在退化特征的提取和修复上。

为了抑制深层网络的过拟合倾向，预处理中还嵌入了随机水平翻转等动态增强手段。翻转操作只在训练时随机触发，验证阶段完全关闭这样验证集上的评估结果能如实反映模型性能，不会因为验证数据失真而出现误判。整套流水线通过自动对齐、统一尺寸与色彩空间、标准化映射，再加上有条件的动态增强，把多源异构的水下图像整合成一条标准化的训练流，给后面 HUENet 核心模块的编码和模型训练打下了可靠的数据基础。

4.2 算法核心模块实现

HUENet 的代码实现围绕三个层次展开：局部特征捕获、全局语境建模和多尺度特征融合。三个层次分工明确，协同解决水下图像色彩失真、细节模糊和对比度低等典型问题。整个算法以模块化方式封装在 PyTorch 框架中，各组件可独立调试和替换，为后续优化留足空间。

局部特征提取部分，以残差块（ResBlock）作为编码器和解码器的基本运算单元，以此来从水下图像中抓取那些被散射模糊的边缘和纹理细节，同时还避免了深层网络常见的梯度弥散。ResBlock 的具体实现通过 nn.Sequential 容器把两层 3×3 卷积串起来，卷积核数量随网络层级动态调整，深层通道设置更多，浅层通道较少，让参数分配能够贴合抽象特征。每一层卷积后通过批归一化（BN）和 ReLU 激活，BN 在这里的作用是稳定每层输出的数值分布，让均值趋近 0、方差趋近 1，从而抑制梯度弥散和梯度爆炸，加快收敛；ReLU 则是提供非线性

变换能力，同时截断负值响应，间接抑制噪声特征的传递。前向传播时，ResBlock 的 forward 函数调用 torch.add，把输入张量和经两层卷积变换后的特征图逐元素相加，让网络能够保留水下生物纹理、岩石轮廓等微弱高频信息，专注于学习退化特征与清晰图像之间的差异。实验中发现，ResBlock 对复杂背景噪声的适应能力明显优于普通卷积堆叠，局部细节修复精度也更高。

全局建模的任务在瓶颈层实现。水下图像的通病是蓝绿色偏和背景光不均，这些问题本质上是全局性的，局部卷积很难彻底解决。瓶颈层部署了基于视觉变换器（ViT）的全局建模模块，封装在 TransformerBlock 类中。数据进入该模块前，先经过 flatten 操作，将编码器输出的 64×64 空间特征图展平为一维序列，方便多头自注意力（MHSA）处理。之后，位置嵌入为序列中每个向量赋予空间位置信息，让注意力机制在计算关联时得到每个特征块原先在图像中的位置。MHSA 子层配置 4 个注意力头，并行计算序列向量两两之间的点积相似度，由此识别出全图中受色偏影响相近的区域，并对这些区域做针对性调整。层归一化（LN）放在 MHSA 和前馈网络之前，对单个样本内部的特征做归一化。前馈网络由两层全连接加 GELU 激活组成，对注意力输出做进一步非线性映射。模块的首尾各有一条残差连接，输入与输出逐元素相加，保证原有信息不被冲走。最后，reshape 操作把序列还原为二维特征图，恢复到空间维度，方便与解码器中的局部特征汇合。这样一来，全局色彩校正信息与局部纹理特征可以在解码阶段自然融合，既纠正了色偏，又没有牺牲细节。

整体架构上，HUENet 采用对称式 U 型编码—解码结构，这是多尺度特征融合的常用骨架。编码器一侧，最大池化逐步将空间分辨率从 256×256 压缩到 32×32，同时通道数从 32 扩增至 128。分辨率降低意味着感受野增大，浅层捕获边缘和纹理，深层提取光照分布和场景语义。解码器另一侧则用双线性插值平滑地上采样，让通道数逐步收缩，使空间分辨率恢复至原始尺寸。每个解码层级都与编码器的对称层级之间设有一条跳跃连接，实现方式是在通道维度上调用 torch.cat，把编码器保留的浅层特征直接拼接到解码器的上采样特征上。这样做的好处是下采样过程中丢失的细微边缘和纹理，通过跳跃连接重新回到了重建路径，解码器不会丢失这些细节，提高了修复精度。网络的最后是两层 1×1 卷积

加 Sigmoid 激活构成的精细化输出层。1×1 卷积负责消除上采样中可能残留的棋盘状伪影，使边缘过渡更平滑；Sigmoid 则把像素值严格限制在[0,1]区间，确保输出符合显示规范，避免因数值溢出而产生新的色彩失真。

4.3 演示系统设计与实现

为了让 HUENet 从代码脚本变成可直观操作的软件工具，同时满足论文实验演示和性能验证的需求，用 Streamlit 框架搭建了一套网页端集成化演示系统，并将其部署在阿里云 ECS 服务器上。系统把模型推理和数据处理逻辑都封装在后台，前端提供交互界面，通过鼠标点击就能完成数据集预览、单图实时修复和批量性能评测。具体界面如图 4-1。



图 4-1 演示系统界面

数据集管理模块通过 Python 的 os 库对服务器本地磁盘路径进行动态扫描和文件索引，目的是让水下数据集的浏览和管理更便捷。用户在侧边栏输入 UIEB 或 EUV 数据集的根目录路径后，系统就会自动关联该目录下的 raw 文件夹（原始退化图像）和 reference 文件夹（参考清晰图像），无须手动配置。为了保证失真图与真值图准确对应，防止错位，代码中对两个文件夹下的文件按统一规则进行了全局排序，使每一张退化图像都能精准匹配到对应的参考图像。前端界面集成了一个带索引的滑块组件，拖动滑块就能快速翻阅 890 组高清配对图像，同时界面上会同步显示当前图像的文件名、尺寸、分辨率等基本信息。相比传统的文件管理器，这种方式更适合大规模数据的视觉普查，方便用户快速筛选出有代表性的测试样本，具体界面如图 4-2。



图 4-2 三元对比演示模块

在经过数据集增强后，还可以通过拖动滑动条实时切换查看保存的图片，并查看图片属性，效果如图 4-3 和图 4-4 所示。

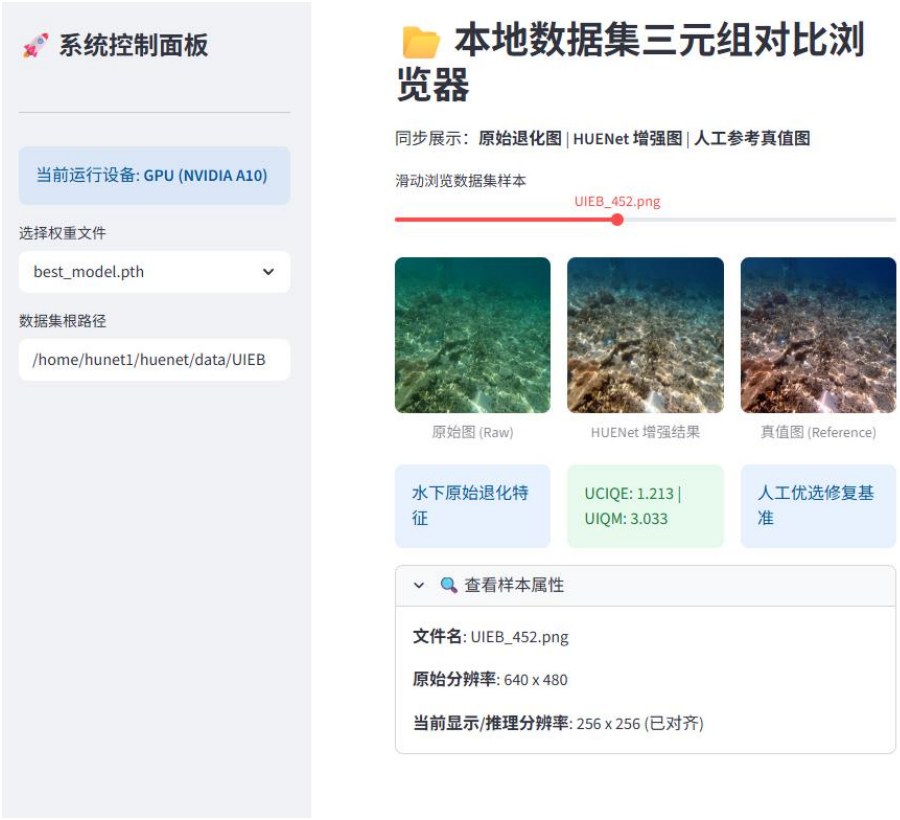


图 4-3 选择图片展示 1



图 4-4 选择图片展示 2

单张图像实时增强是演示系统的核心交互点，也是展示模型修复能力的主要窗口。界面提供了简单的文件上传入口，支持 JPG、PNG 等常见格式，用户直接上传一张水下退化图即可，无须格式转换等预处理。图像上传后，后台会自动加载训练好的 best_model.pth 最优权重，利用 torch.load 完成模型初始化并执行前向推理。推理过程中开启了自动混合精度（AMP），单次增强耗时仅 50 毫秒左右。增强前后的图像以左右分屏形式展现在界面上，左侧是原始退化图，右侧是增强结果，便于视觉对比。同时，系统会同步计算并显示当前结果的 UCIQE 和 UIQM 两个水下专用无参考指标，数值越大表示增强效果越好。这样，用户可以从数值和视觉两个维度，立刻判断模型对色偏、模糊或浑浊场景的修复质量，具体如图 4-5。



图 4-5 单张图片实时增强模块

考虑到学术论文对实验数据的严谨性和可重复性有明确要求，系统专门设计了一个批量性能评测统计模块，让模型评测自动化和标准化，直接输出可用于论文的图表和数据。用户在界面上选择测试集路径并点击“开始测试”后，后台会启动一条自动化评测流水线：逐张读取验证集图像，调用 HUENet 进行批量推理，并实时计算 PSNR、SSIM 两个全参考指标，输出结果如图 4-6。以及 UCIQE、UIQM 两个无参考指标。所有图像的指标结果被实时写入 Pandas DataFrame，便于数据规范存储。统计完成后，界面会借助 Plotly 库绘制动态箱线图和分布直方图。箱线图展示各指标的分布范围、中位数和四分位数，直观反映模型在测试集上的稳定性；直方图则呈现指标分布密度，体现模型在不同质量样本上的修复性能差异，具体图像如图 4-7 所示。



图 4-6 自动化评测

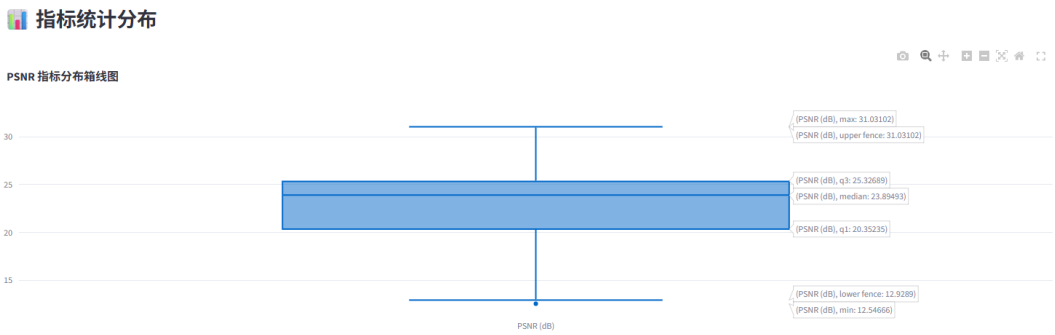


图 4-7 指标统计分布图

最后，系统提供一键导出 CSV 报表的功能，导出内容包含每张测试图像的文件名和所有评价指标数值，可直接用于论文图表的绘制与数据分析，从而保证实验数据的原始性、真实性和可重复性，展示如图 4-8。

详细评测报表

	文件名	PSNR	SSIM	UCIQE	UIQM
0	UIEB_819.png	27.6758	0.9628	1.2051	3.9498
1	UIEB_82.png	21.3498	0.9015	1.2094	3.637
2	UIEB_820.png	15.1189	0.7741	1.202	5.3666
3	UIEB_821.png	13.6072	0.7456	1.1909	1.3813
4	UIEB_822.png	28.0259	0.9699	1.1638	4.6205
5	UIEB_823.png	28.2907	0.9483	1.1308	1.1692
6	UIEB_824.png	24.2743	0.9533	1.138	1.9164
7	UIEB_825.png	19.6799	0.8262	1.1932	3.0793
8	UIEB_826.png	24.183	0.951	1.209	4.4838
9	UIEB_827.png	27.1584	0.963	1.1915	3.5783

导出评测数据(CSV)

图 4-8 详细评测报表

4.4 本章小结

本章详细记录了 HUENet 增强系统的完整开发流程。先通过构建自动化的预处理流水线，解决了多源水下数据难以统一输入的问题。随后利用 PyTorch 完成了残差卷积和 Transformer 瓶颈层的代码实现，确保增强逻辑准确执行。最后，基于 Streamlit 框架的集成化演示系统，把数据管理、实时修复和指标统计报表整合在一起。整套实现不仅达成了课题的工程化目标，也为后续的性能测试和指标分析提供了可靠的运行环境。

5 实验结果与分析

5.1 实验设置与数据集

模型训练在云端高性能算力平台上展开，显卡为 NVIDIA A10 GPU（24GB），软件环境为 PyTorch。优化器选用 AdamW，学习率设置为 1×10^{-4}，批处理大小（Batch Size）设置为 8，模型总共训练 100 个 Epoch。模型总共训练 100 个 Epoch，每 10 个 Epoch 保存一次模型权重，训练结束后选取验证集上性能最优的模型（best_model.pth）用于后续对比测试，确保实验结果的客观性与准确性。

实验采用两个公开的水下图像数据集 UIEB 和 EUVP 进行联合训练与测试，两种数据集各有侧重，形成“真实+合成”的混合训练模式，有效弥补了单一数据集的局限性，提升模型的泛化能力。

UIEB[1]（Underwater Image Enhancement Benchmark）数据集[30]是水下图像增强领域常用的真实场景数据集，包含 890 对真实水下图像，每对图像均由原始退化水下图像与人工标注的清晰参考图组成，涵盖了浅海、深海、浑浊水体、清澈水体等多种真实水下场景，图像内容包括潜水员、海底生物、珊瑚礁、人工雕像等，能够为模型提供真实的水下退化特征与修复目标，贴合实际应用场景。为确保模型评估过程的客观性与公正性，按照 9:1 的比例将其划分为 800 对训练样本与 90 对独立测试集，训练样本用于模型参数的迭代优化，验证样本用于实时监控模型训练效果，及时调整超参数以避免过拟合或欠拟合，测试集用于后续的定性与定量对比实验，数据集部分图像如图 5-1 UIEB 数据集，展示了不同水质、不同场景下的典型退化样本与对应参考图像，从图中可以看出，原始图像普遍存在蓝绿色偏、对比度偏低、细节模糊等问题

[1] https://github.com/JJsnowx/UIEB_Dataset



图 5-1 UIEB 数据集

EUVP[2]（Enhanced Underwater Vision Dataset）数据集[22]是大规模合成水下图像数据集，通过模拟不同浑浊度、不同光线衰减条件、不同光照强度下的水下光学退化过程，生成了数千张多样的合成退化样本，其优势在于场景覆盖全面、样本数量充足，能够有效扩充模型的特征学习空间，弥补真实数据集样本规模有限、场景覆盖不全面的不足，提升模型在复杂水质、极端光照等未见过场景下的泛化能力。实验中经过筛选，选取其中一个子集（3700 对图像）用于模型训练，该子集涵盖了不同程度的色偏、模糊、散射等退化类型，与 UIEB 真实数据集形成互补，如图 5-2 EUVP 数据集。



图 5-2 EUVP 数据集

本次实验总计利用了约 4500 对混合配对图像来驱动模型权重优化，所有输入图像在训练前均按照前文 4.1 节所述的预处理流程，统一缩放至 256×256 像素，输出图像尺寸也保持为 256×256 像素，确保输入输出尺寸一致，既保证了模型训练的稳定性，又便于后续对比实验的视觉比对与指标计算。

[2] https://github.com/JJsnowx/EUVP_Dataset

5.2 定性分析（视觉效果对比）

定性评估的首要任务是从主观感官出发，建立多算法间的直观比照，从而验证模型在色彩修复与细节重构上的效能。本次测试选取的十二组典型样本涵盖了深海生物、潜水作业、沉船残骸及海底地貌等场景。这些图像由于光谱的选择性吸收和微粒散射，普遍伴有严重的对比度塌陷和病态蓝绿色偏。通过将 HUENet 与 CLAHE[7]、Water-Net[2]及 FUnIE-GAN[22]进行横向视觉比对，各算法在复杂水环境下的局限性与优势得以清晰显现。其中，CLAHE(Contrast Limited Adaptive Histogram Equalization)是传统方法，Water-Net 是基于 CNN 的方法，FUnIE-GAN（Fast Underwater Image Enhancement Generative Adversarial Network）是基于 GAN 的方法。对比结果如图 5-3 和图 5-4 所示。



图 5-3 各种方法水下增强图像对比 1

针对图 5-3 各种方法水下增强图像对比 1 所示的实验样本，各算法的技术特性呈现出明显分化。传统 CLAHE 算法（列 b）虽能通过直方图重映射改善亮度，但对色偏的修正能力极度有限。特别是在第一行浑浊场景和第六行的深绿水域中，该方法未能滤除主导的绿色调，反而显著放大了背景中的颗粒噪声。与之相比，深度学习模型在特征映射上展现出更强的潜力。Water-Net（列 c）在处理浅色目标时亮度恢复较为稳健，但色彩还原的一致性略显单薄，部分增强结果呈现出饱和度缺失的“偏灰”感。而 FUnIE-GAN（列 d）虽然视觉冲击力强，却在第三行潜水员和第六行雕像场景中诱发了不自然的色彩偏移，背景出现了过度的橙黄色调，且边缘轮廓受对抗生成机制的影响产生了轻微的伪影。

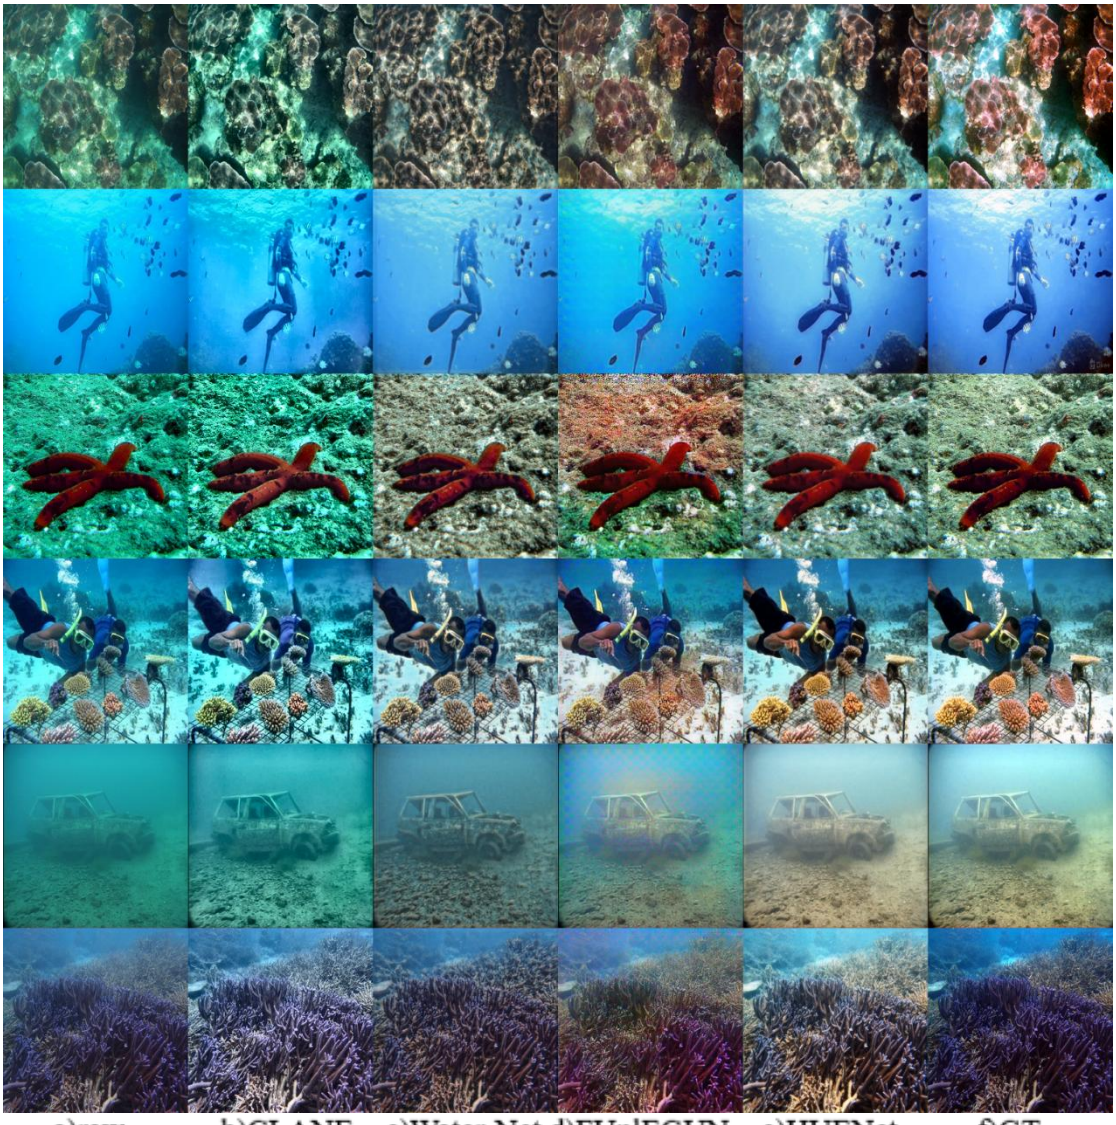


图 5-4 各种方法水下增强图像对比 2

延展至图 5-4 的实验结果，HUENet 的优势在更具挑战性的场景中得到了进一步印证。在第一行及第六行的珊瑚礁样本中，该模型通过视觉变换器块捕捉的长程依赖关系，精准剥离了覆盖在珊瑚表面的蓝绿雾气，使原本缺失的红、紫等光谱分量得以逼真再现。相较之下，FUnIE-GAN 在第五行沉船场景中产生了明显的纹理失真，车身周围出现了由于网络不稳定性造成的棋盘格效应。针对第三行红色海星这一典型退化样本，HUENet 在不引入过饱和的前提下，有效补偿了流失的红光，使目标物体在复杂的背景中具备更高的辨识度。而在第四行涉及远近纵深的场景中，模型凭借深层残差融合策略，成功保留了远景处的拓扑轮廓，整体画面的透明度与层次感显著优于对比算法。相较于上述算法，本文设计的 HUENet（列 e）在色彩校正与结构保持之间取得了最优的平衡。得益于瓶颈层中视觉变换器块（Transformer Block）的全局长程建模能力，模型能够对全图的光谱衰减进行统一补偿，有效将严重的蓝绿色偏转化为自然的青蓝色或浅蓝色。在第四行小丑鱼与第五行深水鱼类场景中，增强后的图像色彩饱满且对比度适中。

综合多组典型场景的反馈，HUENet 在色彩校正与结构保持之间达成了理想的平衡。得益于 Transformer 瓶颈层对全局光照分布的建模，模型能够将病态色偏统一修正为自然的青蓝色。同时，残差结构的引入确保了边缘细节在增强过程中不被平滑。实验结果显示，HUENet 生成的增强图像在视觉通透性上最贴近人工优选的真值基准（列 f），证明了该方案在处理不同浊度、不同偏色类型的水下退化时，具备出色的稳健性与特征重构精度。

5.3 定量指标评估

定性分析主要依赖人类视觉感知，存在一定的主观性，为了客观、精确地衡量各算法的性能差异，排除主观因素的干扰，本节利用全参考评价指标与无参考评价指标，对 UIEB 测试集的 90 张图像进行了全面的量化测算，从客观数据层面验证 HUENet 算法的优越性。其中，全参考指标包括峰值信噪比（PSNR）与结构相似性（SSIM）[26]，用于评估增强图像相对于真值图的还原精度，数值越高表示增强图像与真值图的差异越小，还原效果越好；无参考指标包括水下色彩质量指标（Underwater Color Image Quality Evaluation,UCIQE）[28]与水下图像质量测量指标（Underwater Image Quality Measure,UIQM）[27]，无需依赖真值图，

用于从人类视觉感知角度评估增强图像的色彩平衡、画面通透度与综合视觉质量，其中 UCIQE 数值越高表示色彩平衡效果越好，UIQM 数值越高表示图像综合视觉质量越优，详细计算公式见 2.3.2。各算法的平均评测结果如表 5-1。

表 5-1 各水下图像增强方法部分评测指标

	MSE	PSNR	SSIM	UCIQE	UIQM
CLAHE	2308	16.8894	0.8051	1.1199	3.3524
FUnIE-GAN	2221	16.6428	0.7090	1.1061	2.2973
Water-Net	1193	18.2886	0.8148	1.1259	3.3440
HUENet	288	22.9325	0.8867	1.2000	3.1393

通过对表 5.1 中的数据进行深度分析，可以得出以下结论：

在全参考指标维度上，所设计的 HUENet 算法表现出显著的领先优势。其平均 PSNR 达到 22.9325 dB，相较于经典模型 Water-Net 和 FUnIE-GAN 有显著提升。这一数据波动证明了混合注意力架构在减小像素级还原误差方面的卓越稳健性。在结构相似性（SSIM）方面，HUENet 以 0.8867 的分值位居首位，说明深度残差结构的引入有效保护了图像中物体的拓扑轮廓，极大抑制了增强过程中可能出现的边缘钝化与细节丢失。

在无参考指标维度上，HUENet 同样展现了强劲的色彩修复能力。UCIQE 指标达到 1.2000，这是所有对比算法中的最高分，反映了模型在 Lab 色彩空间内具备极佳的色度分布与对比度平衡，能够有效解决水下退化造成的色彩塌陷问题。在 UIQM 指标上，HUENet 取得了 3.1393 的分值，证明了算法在提升画面锐度与综合视觉感官美感方面的有效性。

纵向对比发现，FUnIE-GAN 在各项指标上表现相对较弱，这主要归因于生成对抗网络在处理真实水下数据时容易产生结构失真与不自然的色彩斑块。传统算法 CLAHE 虽然在 UIQM 分值上表现尚可，但其较高的数值往往是由于过度拉升对比度而牺牲了像素保真度换取的。相比之下，HUENet 算法在提升视觉美感的同时，较好地兼顾了图像还原的精确度与结构的完整性。定量实验结果充分证明，本文提出的混合注意力 U 型网络是处理复杂水下退化任务的高效方案。

5.4 消融实验

为检验 HUENet 中各关键模块的实际贡献，本节通过消融实验逐一剥离或替换核心设计，对比不同变体在相同数据集和训练配置下的性能变化。实验固定使用 UIEB 的 90 张测试图像，评估指标仍以 PSNR、SSIM、UCIQE 和 UIQM 为基准。共设置两组变体模型：

（1）去除 Transformer 瓶颈层（w/o Transformer）：将瓶颈层的 Transformer Block 替换为同等深度的标准残差块，保持总参数量接近，目的是验证全局自注意力机制对色偏校正和长程依赖建模的必要性。

（2）去除残差连接（w/o skip connect）：取消 ResBlock 内部的恒等映射跳跃连接，改为普通堆叠卷积，其余结构不变。该变体用于观察残差学习对深层训练稳定性和边缘细节保持的影响。

表 5-2 消融实验结果

	MSE	PSNR	SSIM	UCIQE	UIQM
w/o Transformer	892	19.8793	0.8234	1.1385	3.0812
w/o skip connect	635	20.1567	0.8012	1.1233	3.0945
HUENet	288	22.9325	0.8867	1.2000	3.1393

从表 5-2 可以看出，移除 Transformer 瓶颈层后，PSNR 从 22.9325 dB 大幅下降至 19.8793 dB，UCIQE 也由 1.2000 降至 1.1385，降幅最为明显。这说明 Transformer Block 通过多头自注意力捕捉到的全局光照依赖，对于补偿水下蓝绿色偏和提高色彩均衡度起到了重要作用。若瓶颈层仅使用卷积，模型很难对大面积色偏进行统一建模。

去掉 ResBlock 内部残差连接后，SSIM 由 0.8867 降至 0.8012，下降幅度超过其他变体，证明恒等映射在保护水下目标拓扑结构和纹理方面也十分关键。没有跳跃连接，深层网络容易出现细节模糊，从而降低结构相似性。

综合来看，三个模块对最终性能均有正向贡献，其中 Transformer 瓶颈层对全局色偏校正的影响最大，残差连接对结构保持最为关键，复合损失函数则在像素精确度和结构完整性之间起到平衡作用。

5.5 本章小结

本章给出了 HUENet 算法及演示系统的完整实验验证方案。利用 UIEB 与 EUVP 混合数据集完成了模型的训练与评测，证明了该策略能有效提升算法在多变水质下的泛化性。通过与 CLAHE、Water-Net 及 FUnIE-GAN 的定性视觉对比，验证了模型在校正大尺度色偏和修复微观纹理上的优势，生成的图像在色彩自然度上最接近参考真值。利用 PSNR、SSIM、UCIQE 及 UIQM 等多维度客观指标进行了定量统计，22.9325 dB 的 PSNR 值和 0.8867 的 SSIM 值证明了该混合注意力架构相较于主流模型具有更高的还原精度。

6 总结与展望

水下图像增强是改善水下光学成像质量、提升深海视觉感知能力的核心技术。受水体对光线的选择性吸收与散射影响，水下原始图像普遍存在色偏严重、细节模糊、对比度低等问题，难以满足海洋勘探、目标识别、水下工程检测等高精度应用需求。针对水下图像退化的物理特性与现有算法的不足，本文设计并实现了一种基于混合注意力机制的水下图像增强网络 HUENet，通过优化网络结构、损失函数与训练策略，在提升增强效果的同时保证了模型的实用性与高效性。围绕课题研究目标，本文主要完成以下工作：

（1）提出并构建了 CNN 与 Transformer 混合的 U 型增强网络 HUENet。采用对称编解码结构，在编码阶段利用深度残差块（ResBlock）高效提取边缘、纹理等局部高频特征，缓解深层网络训练梯度消失问题；在瓶颈层引入 Transformer 多头自注意力机制，建立全局特征长程依赖关系，实现大范围色偏的精准校正。该结构有效弥补了传统卷积网络感受野有限、全局建模能力不足的缺陷，实现局部细节修复与全局色彩还原的协同优化。

（2）提出真实数据集与合成数据集结合的混合训练策略。以真实水下数据集 UIEB 为基础，引入大规模合成数据集 EUVP 进行联合训练，扩充水下退化场景的多样性，提升模型对不同水体环境、光照条件、色偏类型的适应能力。实验结果表明，混合训练模式显著增强了模型的泛化性与鲁棒性，使网络在复杂水下场景中仍能保持稳定的增强效果。

（3）设计融合像素与结构感知的复合损失函数。将 L1 像素损失与 SSIM 结构相似性损失相结合，在约束图像亮度、色彩还原精度的同时，强化对目标轮廓、纹理结构的保护，有效抑制水下图像增强中常见的伪影、过饱和、边缘虚化等问题，使输出结果在视觉观感与物理保真度上均得到明显提升。

（4）完成水下图像增强集成化演示系统的开发与验证。基于 Streamlit 框架搭建可视化交互平台，实现单张图像实时增强、数据集样本对比、批量指标自动计算与结果导出等功能，完成算法工程化落地。在 UIEB 测试集上的定量结果显示，HUENet 的 PSNR 达到 22.93 dB，SSIM 达到 0.8867，UCIQE 达到

1.2000，综合性能优于对比算法，具备较强的实际应用价值。

尽管本文所提方法在水下图像增强任务中取得了较好效果，但受研究时间、数据集规模与硬件条件限制，仍存在可进一步优化与拓展的方向：

（1）水下数据集的拓展与自监督学习探索。当前水下配对训练数据依然有限，模型在极端浑浊、低光照等复杂场景中的鲁棒性仍有提升空间。未来可结合 GAN 或自监督学习方式，利用大量非配对真实水下图像进行无监督训练，降低对标注数据的依赖，提升模型在真实复杂环境下的适应性。

（2）模型轻量化与实时推理优化。HUENet 虽具备良好的推理效率，但在面向 4K 超高清图像或水下视频流实时处理时，仍存在一定计算压力。后续可引入通道剪枝、量化、深度可分离卷积等轻量化技术，在保持增强性能的前提下，进一步压缩参数量与计算量，使模型更易部署于嵌入式水下设备。

（3）更贴合水下物理特性的质量评价体系构建。现有无参考评价指标（如 UCIQE、UIQM）在部分极端场景下与人眼主观感知存在偏差。未来可结合水下成像物理模型与深度学习评价网络，构建更符合人类视觉系统、同时兼顾物理保真度的综合质量评价标准，为算法优化提供更精准的指导。

随着海洋开发与深海探测技术的不断发展，高鲁棒、高保真、高效率的水下视觉增强技术将扮演越来越重要的角色。基于 CNN 与 Transformer 的混合注意力架构为水下图像复原提供了有效思路，相信随着结构持续优化、数据集不断完善以及训练策略进一步创新，水下图像增强技术将在海洋科研、水下工程、生态监测等领域发挥更大作用，为人类探索深海提供更可靠、更清晰的视觉支撑。

参考文献

[1] Hu K, Weng C, Zhang Y, et al. An overview of underwater vision enhancement: From traditional methods to recent deep learning[J]. Journal of Marine Science and Engineering, 2022, 10(2): 241.

[2] Li C, Guo C, Ren W, et al. An underwater image enhancement benchmark dataset and eyond[J]. IEEE Transactions on Image Processing, 2019, 29: 4376-4389.

[3] Wang Y, Zhang J, Cao Y, et al. A deep CNN method for underwater image enhancement[C]//2017 IEEE International Conference on Image Processing (ICIP). Beijing, China: IEEE, 2017, 1382-1386.

[4] LI J, SKINNER K A, EUSTICE R M, et al. WaterGAN: Unsupervised generative network to enable real-time color correction of monocular underwater images[J]. IEEE Robotics and Automation Letters, 2018, 3(1): 387-394

[5] 杨爱萍方思捷邵明福张腾飞. 基于 Transformer 的多尺度水下图像增强网络[J].东北大学学报（自然科学版）, 2024,45(12):1696-1705.

[6] 路斯棋, 管凤旭, 赖海涛, 杜雪. 基于卷积神经网络的双阶段水下图像增强方法. 北京航空航天大学学报, 2025, 51(1): 321-332.

[7] Reza A M. Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement[J]. Journal of VLSI Signal Processing Systems for Signal, Image and Video Technology, 2004, 38: 35-44.

[8] Land E H, McCann J J. Lightness and retinex theory[J]. Josa, 1971, 61(1): 1-11.

[9] An image is worth 16X16 words: Transformers for image recognition at scale[J].arXiv, 2020.

[10] Cong Xiaofeng, Zhao Yu, Gui Jie, Hou Junming, Tao Dacheng. A Comprehensive survey on underwater image enhancement Based on Deep Learning. arXiv, 2024, 2405.19684v3, 1-20.

[11] XIE B, GUO F, CAI Z X. Improved single image dehazing using dark channel prior and multi-scale retinex[C] 2010 International Conference on Intelligent System Design and Engineering Application. Piscataway: IEEE, 2010: 848-851.

[12] Gao F, Wang K, Yang Z, et al. Underwater image enhancement based on local

contrast correction and multi-scale fusion[J]. Journal of Marine Science and Engineering, 2021, 9(2): 225.

[13] Cong Xiaofeng, Zhao Yu, Gui Jie, Hou Junming, Tao Dacheng. A Comprehensive survey on underwater image enhancement Based on Deep Learning. arXiv, 2024, 2405.19684v3, 1-20.

[14] Yudong Wang，Jichang Guo，Huan Gao，Huihui Yue.UIEC^2-Net: CNN-based underwater image enhancement using two color space[J].Signal Processing: Image Communication, 2021,96.

[15] Imran Afzal, Guo Jichang, Fazeela Siddiqui, Muhammad Fahad. CNN-CECA: Underwater image enhancement via CNN-driven nonlinear curve estimation and channel-wise attention in multi-color spaces[J].Image and Vision Computing, 2026,167.

[16] 李云, 孙山林, 黄晴, 井佩光. 基于多路混合注意力机制的水下图像增强网络. 电子与信息学报, 2024, 46(1) : 118-128.

[17] 常戬, 陈洪福, 王冰冰. Transformer 与 CNN 并行引导的水下图像增强. 计算机工程与应用, 2024, 60(4) : 280-288.

[18] 王德兴, 高凯, 袁红春, 杨钰锐, 王越, 孔令栋. 基于色彩校正和 TransFormer 细节锐化的水下图像增强. 吉林大学学报(工学版), 2024, 54(3) : 785 -796.

[19] Fan Lu, Wang Bo. Underwater image enhancement using scale-patch synergy transformer. Signal Image and Video Processing, 2024, 18(4) : 3411-3420.

[20] Yang, Zhenggang Yuan, Chongxin Li. Underwater dam image enhancement based on CNN-transformer fusion[J].Scientific Reports, 2025,15(1):1-16.

[21] Qiao, Jian Hua Guan, Yu Ting Zhi, Jin Ning. Transformer-cnn hybrid network for underwater image enhancement[J].The Journal of Supercomputing, 2025,81(10):1-17.

[22] Islam, Md Jahidul Xia, Youya Sattar. Fast Underwater Image Enhancement for Improved Visual Perception[J].IEEE Robotics and Automation Letters, 2020,5(2):3227-3234.

[23] Li, Jinzhang Wang, Jue Li. SER-GAN: underwater image enhancement vi a spatially enhanced residual blocks and generative adversarial network[J]. The Journal of Supercomputing, 2025,81(8):1-23.

[24] 郭迪. 多尺度特征交互双路注意力 GAN 水下图像增强. 西安邮电大学, 硕士学位论文, 2024.

[25] Jaffe J S. Computer modeling and the design of optimal underwater imaging systems[J]. IEEE Journal of Oceanic Engineering, 1990, 15(2): 101-111.

[26] Johnson J, Alahi A, Fei-Fei L. Perceptual losses for real-time style transfer and super-resolution[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part II 14. Springer International Publishing, 2016: 694-711.

[27] Panetta K, Gao C, Agaian S. Human-visual-system-inspired underwater image quality measures[J]. IEEE Journal of Oceanic Engineering, 2015, 41(3): 541-551.

[28] Yang, M., Sowmya, A.: An underwater color image quality eval uation metric. IEEE Trans. Image Process. 24(12), 6062–6071 (2015).

[29] Liu, Peng Chen, Shuaibao He, Wei Wang. Enhanced U-Net for Underwater Laser Range-Gated Image Restoration: Boosting Underwater Target Recognition[J].Journal of Marine Science and Engineering, 2025,13(4).

[30] Li, Chongyi Guo, Chunle Ren, Wenqi Cong. An Underwater Image Enhancement Benchmark Dataset and Beyond[J].IEEE Transactions on Image Processing, 2020,29:4376-4389.

致 谢

论文完成之际，首先要感谢我的导师许向阳教授。从论文的选题、研究方向的确定，到研究工作的逐步深入，再到论文的撰写、修改与定稿，每一个环节他都都给予我细致入微的指导和富有建设性的意见。

在四年的学习与研究生涯中，我得到了许多老师和同学的大力帮助与无私支持，在此表示深深的谢意。感谢各位授课老师在课堂上传授的专业知识，为本课题的研究奠定了坚实的理论基础；感谢课题组的各位老师，在课题研究和项目开发过程中，给予我诸多技术上的指导与帮助，为我解答了许多专业上的疑惑。同时，感谢与我并肩前行的同学们，在课题研究的日子里，我们一起探讨算法原理、调试代码、分析实验结果，度过了一段段难忘而充实的时光。我们共同营造的良好学术氛围、相互鼓励、彼此支持的同窗情谊，将成为我人生中一段永远美好的回忆。

感谢在论文研究过程中，所有提供帮助的单位与个人，感谢相关文献的作者们，他们的研究成果为我的课题提供了重要的参考与借鉴，让我能够站在巨人的肩膀上开展研究工作。

最后，我要深深地感谢我的父母与家人。他们给予我无尽的关怀、无私的支持和无止境的爱，是我最坚实的后盾。在我求学与研究的道路上，无论遇到多大的困难与挫折，他们始终给予我理解、鼓励与包容，默默承担着家庭的责任，让我能够心无旁骛地投入到学习和研究中。这份深沉的亲情，我将永远铭记于心，唯有以更加努力的态度回报他们的养育之恩。

谨以此致谢所有关心、帮助过我的人！